Прогнозирование с советами экспертов

Е.А. Цыбулин

27 октября 2026 г.

1 Стандартная постановка задачи и основные определения

Рассматривается задача прогнозирования временного ряда с использованием экспертных стратегий (*prediction with expert advice*). *Временной ряд* $y = (y_1, y_2, \dots)$ представляет собой последовательность элементов некоторого множества $\mathcal{Y}$, называемых исходами. В рамках данной теории строятся алгоритмы, называемые *смешивающими прогнозирующими алгоритмами (ПА)*, объединяющие предсказания следующего исхода различных методов прогнозирования.

Экспертные стратегии (далее — *эксперты*) могут иметь совершенно разную природу — это могут быть некоторые правила, функции, алгоритмы, оценки специалистов и т.д. Каждый эксперт может быть эффективнее других на определённых участках ряда.

Классическая задача заключается в том, что в режиме онлайн на шагах $t = 1, 2, \dots$ генерируются исходы $y_1, y_2, \dots \in \mathcal{Y}$. В каждый момент времени $t \in \mathbb{N}$ смешивающий ПА, зная предыдущие исходы, а также предсказания γ_t^i, $i = 1, \dots, N$ из множества допустимых прогнозов $\mathcal{D}$ конечного числа экспертов из множества $I = \{1, \dots, N\}$, делает свой прогноз $\gamma_t \in \mathcal{D}$. После того, как становится следующий исход y_t, каждый эксперт, а также смешивающий ПА оцениваются величиной потерь.

Потери на шаге t равны значению *функции потерь (лосс)*

$$\ell : \mathcal{D} \times \mathcal{Y} \to [0, +\infty)$$

на паре (γ_t, y_t) для смешивающего ПА и на паре (γ_t^i, y_t) — для эксперта i. Примеры функций потерь:

$$\ell(\gamma, y) = \lambda_1 |\gamma - y|_+ + \lambda_2 |y - \gamma|_+,$$

где $|x|_+ := \max(x, 0)$,

$$\ell(\gamma, y) = (\gamma - y)^2, \quad \ell(\gamma, y) = [\![\gamma \neq y]\!].$$

Также имеют место суммарные (кумулятивные) потери на отрезке $t = 1, \dots, T$:

$$L_T := \sum_{t=1}^{T} \ell(\gamma_t, y_t), \quad L_T^i := \sum_{t=1}^{T} \ell(\gamma_t^i, y_t).$$

Наша цель — получить смешивающий ПА, который выдаёт ответы, наиболее близкие к ответам наилучшего эксперта. Поскольку происхождение исходов нам неизвестно (природа временного ряда необязательно имеет вероятностный характер, поэтому исходы могут иметь как стохастическую природу, так и детерминированную или вообще враждебную по отношению к прогнозирующему алгоритму), то нельзя определить понятие риска. Основной гарантией эффективности алгоритма является *регрет относительно лучшего фиксированного эксперта*:

$$R_T := L_T - \min_{1 \leqslant i \leqslant N} L_T^i.$$

2 Смешивание потерь

Определим понятие вероятностного распределения на множестве $I = \{1, \ldots, N\}$, которое представляет собой произвольный вектор $\bar{p}_t = (p^1, \ldots, p^N)$, где $\sum\limits_{i=1}^{N} p^i = 1$, $p^i \geqslant 0$, $i = 1, \ldots, N$. Множество всех вероятностных распределений будем обозначать I^Δ.

Рассмотрим задачу смешивания потерь: пусть на каждом шаге известны только потери экспертов (конкретная функция потерь может отсутствовать). На каждом шаге $t = 1, 2, \ldots$:

1. смешивающий ПА находит вектор распределения экспертов $\bar{p}_t = (p^1, \ldots, p^N) \in I^\Delta$;
2. эксперты объявляют потери ℓ_t^i, также пусть $\bar{\ell}_t = (\ell_t^1, \ldots, \ell_t^N)$;
3. смешивающий ПА подсчитывает свои потери $\ell_t = (\bar{p}_t \cdot \bar{\ell}_t) := \sum\limits_{i=1}^{N} p_t^i \cdot \ell_t^i$;
4. смешивающий ПА пересчитывает вектор распределения.

Предполагаем, что потери экспертов ограничены, например, $\ell_t^i \in [0, 1]$ $\forall t \in \mathbb{N}$, $\forall i \in \{1, \ldots, N\}$. Определим кумулятивные потери:

$$L_T = \sum_{i=1}^{T} (\bar{p}_t \cdot \bar{\ell}_t), \quad L_T^i = \sum_{i=1}^{T} \ell_t^i.$$

Задача смешивающего ПА заключается в подборе вектора распределения таким образом, что

$$R_T = L_T - \min_{1 \leqslant i \leqslant N} L_T^i \to \min_{I^\Delta}.$$

2.1 Экспоненциальное смешивание потерь

Для решения задачи рассмотрим алгоритм $Hedge(\eta)$, который имеет входные параметры η — параметр обучения и начальный набор весов экспертов $(w_1^1, \ldots, w_1^N)$. Пусть веса экспертов в начальный момент времени определены равномерным распределением, то есть $w_1^i = \frac{1}{N}$, $\forall i \in I$. Для моментов времени $t = 1, 2, \ldots$:

- алгоритм вычисляет $\bar{p}_t = \frac{\bar{w_t}}{\sum\limits_{i=1}^{N} w_t^i}$ — вектор распределения экспертов;
- эксперты объявляют свои потери ℓ_t^i, также пусть $\bar{\ell}_t = (\ell_t^1, \ldots, \ell_t^N)$;
- алгоритм подсчитывает свои потери $\ell_t = (\bar{p}_t \cdot \bar{\ell}_t) := \sum\limits_{i=1}^{N} p_t^i \cdot \ell_t^i$;
- алгоритм пересчитывает веса экспертов

$$w_{t+1}^i = w_t^i \cdot \exp\left(-\eta \ell_t^i\right).$$

Определим кумулятивные потери:

$$H_T = \sum_{s=1}^{T} \ell_s, \quad L_T^i = \sum_{s=1}^{T} \ell_s^i.$$

Легко видеть, что

$$w_t^i = w_1^i \cdot \exp\left(-\eta L_{t-1}^i\right).$$

Введём следующее понятие смешанной потери алгоритма:

$$m_t := -\frac{1}{\eta} \ln \left(\sum_{i=1}^{N} p_t^i \cdot \exp\left(-\eta \ell_t^i\right) \right).$$

Очевидным образом определяются кумулятивные смешанные потери:

$$M_T := \sum_{t=1}^{T} m_t.$$

Определим $W_t = \sum\limits_{i=1}^{N} w_t^i$ для всех t, тогда из определения следует, что $p_t^i = \frac{w_t^i}{W_t}$.

Лемма (Представление кумулятивных смешанных потерь)**.** *Для любого $T \geqslant 1$ выполнено*

$$M_T = -\frac{1}{\eta} \ln W_{T+1} = -\frac{1}{\eta} \ln \left(\sum_{i=1}^{N} w_1^i \exp\left(-\eta L_T^i\right) \right). \tag{2.1}$$

Доказательство. По правилу обновления весов

$$\sum_{i=1}^{N} p_t^i \exp\left(-\eta \ell_t^i\right) = \frac{1}{W_t} \sum_{i=1}^{N} w_t^i \exp\left(-\eta \ell_t^i\right) = \frac{W_{t+1}}{W_t}.$$

Следовательно, поскольку $W_1 = \sum_{i=1}^{N} w_1^i = 1$,

$$\begin{aligned} M_T &= -\frac{1}{\eta} \sum_{t=1}^{T} \ln \frac{W_{t+1}}{W_t} = -\frac{1}{\eta} \ln \prod_{t=1}^{T} \frac{W_{t+1}}{W_t} \\ &= -\frac{1}{\eta} \ln \frac{W_{T+1}}{W_1} = -\frac{1}{\eta} \ln W_{T+1}. \end{aligned}$$

Второе равенство в (2.1) следует из представления $w_{T+1}^i = w_1^i \exp\left(-\eta L_T^i\right)$. □

Лемма (Сравнение с потерями эксперта)**.** *Для любого эксперта $i \in I$ и любого $T \geqslant 1$*

$$M_T \leqslant -\frac{1}{\eta} \ln w_{T+1}^i = L_T^i + \frac{1}{\eta} \ln \frac{1}{w_1^i} = L_T^i + \frac{\ln N}{\eta}. \tag{2.2}$$

Доказательство. Так как $W_{T+1} = \sum_{j=1}^{N} w_{T+1}^j \geqslant w_{T+1}^i$, из (2.1) получаем первое неравенство. Остальные равенства следуют из формул $w_{T+1}^i = w_1^i \exp\left(-\eta L_T^i\right)$ и $w_1^i = 1/N$. □

Следующие вспомогательные свойства используются при переходе к переменному параметру обучения. Обозначим через m_t^η и M_T^η смешанные и кумулятивные смешанные потери алгоритма с постоянным параметром η. При сравнении разных значений η последовательность потерь экспертов и начальные веса остаются одними и теми же; веса p_t^i вычисляются с соответствующим параметром. Положим также

$$\ell_t^- := \min_{i \in I} \ell_t^i, \qquad \ell_t^+ := \max_{i \in I} \ell_t^i.$$

Лемма (Границы и монотонность смешанных потерь)**.** *Для постоянного параметра обучения $\eta \in (0, \infty)$ выполнены следующие свойства:*

1. *На каждом шаге t*

$$\ell_t^- \leqslant m_t^\eta \leqslant \sum_{i=1}^N p_t^i \ell_t^i = \ell_t \leqslant \ell_t^+. \tag{2.3}$$

2. *Кумулятивные смешанные потери M_T^η являются невозрастающей функцией параметра обучения:*

$$M_T^\eta \geqslant M_T^\mu \qquad \text{при } 0 < \eta \leqslant \mu < \infty. \tag{2.4}$$

Доказательство. Так как $\ell_t^i \geqslant \ell_t^-$ для всех i, имеем

$$\sum_{i=1}^N p_t^i \exp\left(-\eta \ell_t^i\right) \leqslant \exp\left(-\eta \ell_t^-\right) \sum_{i=1}^N p_t^i = \exp\left(-\eta \ell_t^-\right).$$

Применяя к обеим частям функцию $x \mapsto -\eta^{-1} \ln x$, получаем $m_t^\eta \geqslant \ell_t^-$. Кроме того, $\ell_t = \sum_{i=1}^N p_t^i \ell_t^i \leqslant \ell_t^+$, поскольку $\bar{p}_t$ является вероятностным распределением.

Для доказательства неравенства $m_t^\eta \leqslant \ell_t$ воспользуемся неравенством Йенсена:

$$\varphi(\mathbb{E}X) \leqslant \mathbb{E}\varphi(X),$$

где φ — выпуклая функция, а X — случайная величина. Пусть X принимает значения ℓ_t^i с вероятностями p_t^i, $i \in I$. Применяя неравенство Йенсена к выпуклой функции $\varphi(x) = \exp(-\eta x)$, получаем

$$\exp\left(-\eta \sum_{i=1}^N p_t^i \ell_t^i\right) \leqslant \sum_{i=1}^N p_t^i \exp\left(-\eta \ell_t^i\right).$$

После логарифмирования и умножения на $-1/\eta$ это даёт

$$m_t^\eta = -\frac{1}{\eta} \ln\left(\sum_{i=1}^N p_t^i \exp\left(-\eta \ell_t^i\right)\right) \leqslant \sum_{i=1}^N p_t^i \ell_t^i = \ell_t.$$

Докажем монотонность. Пусть $0 < \eta \leqslant \mu < \infty$. Функция $x \mapsto x^{\eta/\mu}$ вогнута на $(0, \infty)$, поэтому по неравенству Йенсена

$$\begin{aligned}\sum_{i=1}^N w_1^i \exp\left(-\eta L_T^i\right) &= \sum_{i=1}^N w_1^i \left(\exp\left(-\mu L_T^i\right)\right)^{\eta/\mu} \\ &\leqslant \left(\sum_{i=1}^N w_1^i \exp\left(-\mu L_T^i\right)\right)^{\eta/\mu}.\end{aligned}$$

Используя (2.1), заключаем, что

$$\begin{aligned}M_T^\eta &= -\frac{1}{\eta} \ln\left(\sum_{i=1}^N w_1^i \exp\left(-\eta L_T^i\right)\right) \\ &\geqslant -\frac{1}{\mu} \ln\left(\sum_{i=1}^N w_1^i \exp\left(-\mu L_T^i\right)\right) = M_T^\mu.\end{aligned}$$

□

2.2 Смешивание с переменным параметром обучения

В алгоритме AdaHedge [5] параметр обучения $\eta_t \in (0, \infty)$ может меняться от шага к шагу. При этом веса вычисляются заново по кумулятивным потерям экспертов за предыдущие $t-1$ шагов:

$$w_t^i = w_1^i \exp\left(-\eta_t L_{t-1}^i\right), \qquad p_t^i = \frac{w_t^i}{W_t} = \frac{\exp\left(-\eta_t L_{t-1}^i\right)}{\sum_{j=1}^N \exp\left(-\eta_t L_{t-1}^j\right)}.$$

Здесь $w_1^i = 1/N$ и $L_0^i = 0$, поэтому $p_1^i = 1/N$.

Смешанные потери на шаге t теперь имеют вид

$$\begin{aligned} m_t &= -\frac{1}{\eta_t} \ln\left(\sum_{i=1}^N p_t^i \exp\left(-\eta_t \ell_t^i\right)\right) \\ &= -\frac{1}{\eta_t} \ln\left(\frac{\sum_{i=1}^N \exp\left(-\eta_t L_t^i\right)}{\sum_{j=1}^N \exp\left(-\eta_t L_{t-1}^j\right)}\right). \end{aligned} \tag{2.5}$$

Обозначение M_t^η сохраняем для кумулятивных смешанных потерь с одним и тем же постоянным параметром η на всех шагах. Полагая $M_0^\eta = 0$, из (2.1) и (2.5) получаем

$$m_t = M_t^{\eta_t} - M_{t-1}^{\eta_t}. \tag{2.6}$$

В то же время $M_T = \sum_{t=1}^T m_t$ обозначает кумулятивные смешанные потери алгоритма с последовательностью параметров $\eta_1, \ldots, \eta_T$.

Лемма (Оценка при невозрастающем параметре обучения)**.** *Если* $\eta_1 \geqslant \eta_2 \geqslant \cdots \geqslant \eta_T > 0$, *то*

$$M_T \leqslant M_T^{\eta_T}, \tag{2.7}$$

где правая часть соответствует постоянному параметру $\eta = \eta_T$ *на всех* T *шагах.*

Доказательство. По (2.4), из $\eta_t \geqslant \eta_{t+1}$ следует $M_t^{\eta_t} \leqslant M_t^{\eta_{t+1}}$. Поэтому, используя (2.6) и $M_0^{\eta_1} = 0$, имеем

$$\begin{aligned} M_T &= \sum_{t=1}^T \left(M_t^{\eta_t} - M_{t-1}^{\eta_t}\right) \\ &= M_T^{\eta_T} + \sum_{t=1}^{T-1} \left(M_t^{\eta_t} - M_t^{\eta_{t+1}}\right) \leqslant M_T^{\eta_T}. \end{aligned}$$

□

Наконец, объединяя (2.7), (2.1) и (2.2), для любого эксперта $i \in I$ получаем

$$\begin{aligned} M_T \leqslant M_T^{\eta_T} &= -\frac{1}{\eta_T} \ln\left(\sum_{j=1}^N w_1^j \exp\left(-\eta_T L_T^j\right)\right) \\ &\leqslant L_T^i + \frac{\ln N}{\eta_T}. \end{aligned} \tag{2.8}$$

3 Основные результаты

Рассмотрим алгоритм sAdaHedge для экспертов-специалистов, впервые представленный в статье [3]. Постановка задачи такая же, как и прежде, но теперь множество экспертов

разделено на два подмножества — активных и «спящих» экспертов — в этом и заключается их специализированность. Множество активных экспертов на шаге t обозначим $E_t \subset \{1, \ldots, N\}$. Потери активных экспертов определены так же, как и ранее: ℓ_t^i для эксперта i, а для спящих потери не определены. Кумулятивные потери определим следующим образом:

$$\mathcal{L}_T^i := \sum_{t:i \in E_t}^{T} \ell_t^i.$$

Список литературы

[1] Cesa-Bianchi N., Lugosi G. *Prediction, Learning, and Games*. Cambridge University Press, 2006. Страница книги.

[2] Freund Y., Schapire R. E. A decision-theoretic generalization of on-line learning and an application to boosting. *Journal of Computer and System Sciences*. 1997. Vol. 55, no. 1. P. 119–139. Авторская версия.

[3] V'yugin V. V., Shamsutdinov A. I. Trading-Network Order Formation with the Help of the Aggregation of Specialized Forecast Algorithms. *Journal of Communications Technology and Electronics*. 2016. Vol. 61. P. 1400–1410. https://doi.org/10.1134/S1064226916120251.

[4] Adamskiy D., Koolen W. M., Chernov A., Vovk V. A Closer Look at Adaptive Regret. *Journal of Machine Learning Research*. 2016. Vol. 17, no. 23. P. 1–21. https://www.jmlr.org/papers/v17/13-533.html.

[5] De Rooij S., Van Erven T., Grünwald P. D., Koolen W. M. Follow the Leader If You Can, Hedge If You Must. *Journal of Machine Learning Research*. 2014. Vol. 15, no. 37. P. 1281–1316. https://www.jmlr.org/papers/v15/rooij14a.html.

[6] Devaine M., Gaillard P., Goude Y., Stoltz G. Forecasting electricity consumption by aggregating specialized experts. *Machine Learning*. 2013. Vol. 90, no. 2. P. 231–260. https://doi.org/10.1007/s10994-012-5314-7.

[7] Вьюгин В. В., Шамсутдинов А. И. Формирование заказов торговой сети с помощью агрегирования специализированных алгоритмов прогнозирования. *Информационные процессы*. 2016. Т. 16, № 1. С. 72–89.