Адаптивное агрегирование прогнозов специализированных экспертов

Е.А. Цыбулин

28 октября 2026 г.

1 Стандартная постановка задачи и основные определения

Рассматривается задача прогнозирования временного ряда с использованием экспертных стратегий (*prediction with expert advice*). *Временной ряд* $y = (y_1, y_2, \dots)$ представляет собой последовательность элементов некоторого множества $\mathcal{Y}$, называемых исходами. В рамках данной теории строятся алгоритмы, называемые *смешивающими прогнозирующими алгоритмами (ПА)*, объединяющие предсказания следующего исхода различных методов прогнозирования.

Экспертные стратегии (далее — *эксперты*) могут иметь совершенно разную природу — это могут быть некоторые правила, функции, алгоритмы, оценки специалистов и т.д. Каждый эксперт может быть эффективнее других на определённых участках ряда.

Классическая задача заключается в том, что в режиме онлайн на шагах $t = 1, 2, \dots$ генерируются исходы $y_1, y_2, \dots \in \mathcal{Y}$. В каждый момент времени $t \in \mathbb{N}$ смешивающий ПА, зная предыдущие исходы, а также предсказания γ_t^i, $i = 1, \dots, N$ из множества допустимых прогнозов $\mathcal{D}$ конечного числа экспертов из множества $I = \{1, \dots, N\}$, делает свой прогноз $\gamma_t \in \mathcal{D}$. После того, как становится следующий исход y_t, каждый эксперт, а также смешивающий ПА оцениваются величиной потерь.

Потери на шаге t равны значению *функции потерь (лосс)*

$$\ell : \mathcal{D} \times \mathcal{Y} \to [0, +\infty)$$

на паре (γ_t, y_t) для смешивающего ПА и на паре (γ_t^i, y_t) — для эксперта i. Примеры функций потерь:

$$\ell(\gamma, y) = \lambda_1 |\gamma - y|_+ + \lambda_2 |y - \gamma|_+,$$

где $|x|_+ := \max(x, 0)$,

$$\ell(\gamma, y) = (\gamma - y)^2, \quad \ell(\gamma, y) = [\![\gamma \neq y]\!].$$

Также имеют место суммарные (кумулятивные) потери на отрезке $t = 1, \dots, T$:

$$L_T := \sum_{t=1}^{T} \ell(\gamma_t, y_t), \quad L_T^i := \sum_{t=1}^{T} \ell(\gamma_t^i, y_t).$$

Наша цель — получить смешивающий ПА, который выдаёт ответы, наиболее близкие к ответам наилучшего эксперта. Поскольку происхождение исходов нам неизвестно (природа временного ряда необязательно имеет вероятностный характер, поэтому исходы могут иметь как стохастическую природу, так и детерминированную или вообще враждебную по

отношению к прогнозирующему алгоритму), то нельзя определить понятие риска. Основной гарантией эффективности алгоритма является *регрет относительно лучшего фиксированного эксперта*:

$$R_T := L_T - \min_{1 \leqslant i \leqslant N} L_T^i.$$

2 Смешивание потерь

Определим понятие вероятностного распределения на множестве $I = \{1, \ldots, N\}$, которое представляет собой произвольный вектор $\bar{p}_t = (p^1, \ldots, p^N)$, где $\sum\limits_{i=1}^{N} p^i = 1$, $p^i \geqslant 0$, $i = 1, \ldots, N$. Множество всех вероятностных распределений будем обозначать I^Δ.

Рассмотрим задачу смешивания потерь: пусть на каждом шаге известны только потери экспертов (конкретная функция потерь может отсутствовать). На каждом шаге $t = 1, 2, \ldots$:

1. смешивающий ПА находит вектор распределения экспертов $\bar{p}_t = (p^1, \ldots, p^N) \in I^\Delta$;
2. эксперты объявляют потери ℓ_t^i, также пусть $\bar{\ell}_t = (\ell_t^1, \ldots, \ell_t^N)$;
3. смешивающий ПА подсчитывает свои потери $\ell_t = (\bar{p}_t \cdot \bar{\ell}_t) := \sum\limits_{i=1}^{N} p_t^i \cdot \ell_t^i$;
4. смешивающий ПА пересчитывает вектор распределения.

Предполагаем, что потери экспертов ограничены, например, $\ell_t^i \in [0, 1]$ $\forall t \in \mathbb{N}$, $\forall i \in \{1, \ldots, N\}$. Определим кумулятивные потери:

$$L_T = \sum_{i=1}^{T} (\bar{p}_t \cdot \bar{\ell}_t), \quad L_T^i = \sum_{i=1}^{T} \ell_t^i.$$

Задача смешивающего ПА заключается в подборе вектора распределения таким образом, что

$$R_T = L_T - \min_{1 \leqslant i \leqslant N} L_T^i \to \min_{I^\Delta}.$$

2.1 Экспоненциальное смешивание потерь

Для решения задачи рассмотрим алгоритм $Hedge(\eta)$, который имеет входные параметры η — параметр обучения и начальный набор весов экспертов $(w_1^1, \ldots, w_1^N)$. Пусть веса экспертов в начальный момент времени определены равномерным распределением, то есть $w_1^i = \frac{1}{N}$, $\forall i \in I$. Для моментов времени $t = 1, 2, \ldots$:

- алгоритм вычисляет $\bar{p}_t = \frac{\bar{w}_t}{\sum\limits_{i=1}^{N} w_t^i}$ — вектор распределения экспертов;
- эксперты объявляют свои потери ℓ_t^i, также пусть $\bar{\ell}_t = (\ell_t^1, \ldots, \ell_t^N)$;
- алгоритм подсчитывает свои потери $\ell_t = (\bar{p}_t \cdot \bar{\ell}_t) := \sum\limits_{i=1}^{N} p_t^i \cdot \ell_t^i$;
- алгоритм пересчитывает веса экспертов

$$w_{t+1}^i = w_t^i \cdot \exp\left(-\eta \ell_t^i\right).$$

Определим кумулятивные потери:

$$H_T = \sum_{s=1}^{T} \ell_s, \quad L_T^i = \sum_{s=1}^{T} \ell_s^i.$$

Легко видеть, что

$$w_t^i = w_1^i \cdot \exp\left(-\eta L_{t-1}^i\right).$$

Введём следующее понятие смешанной потери алгоритма:

$$m_t := -\frac{1}{\eta} \ln \left(\sum_{i=1}^{N} p_t^i \cdot \exp\left(-\eta \ell_t^i\right) \right).$$

Очевидным образом определяются кумулятивные смешанные потери:

$$M_T := \sum_{t=1}^{T} m_t.$$

Определим $W_t = \sum\limits_{i=1}^{N} w_t^i$ для всех t, тогда из определения следует, что $p_t^i = \frac{w_t^i}{W_t}$.

Лемма (Представление кумулятивных смешанных потерь)**.** *Для любого $T \geqslant 1$ выполнено*

$$M_T = -\frac{1}{\eta} \ln W_{T+1} = -\frac{1}{\eta} \ln \left(\sum_{i=1}^{N} w_1^i \exp\left(-\eta L_T^i\right) \right). \tag{2.1}$$

Доказательство. По правилу обновления весов

$$\sum_{i=1}^{N} p_t^i \exp\left(-\eta \ell_t^i\right) = \frac{1}{W_t} \sum_{i=1}^{N} w_t^i \exp\left(-\eta \ell_t^i\right) = \frac{W_{t+1}}{W_t}.$$

Следовательно, поскольку $W_1 = \sum_{i=1}^{N} w_1^i = 1$,

$$M_T = -\frac{1}{\eta} \sum_{t=1}^{T} \ln \frac{W_{t+1}}{W_t} = -\frac{1}{\eta} \ln \prod_{t=1}^{T} \frac{W_{t+1}}{W_t} = -\frac{1}{\eta} \ln \frac{W_{T+1}}{W_1} = -\frac{1}{\eta} \ln W_{T+1}.$$

Второе равенство в (2.1) следует из представления $w_{T+1}^i = w_1^i \exp\left(-\eta L_T^i\right)$. □

Лемма (Сравнение с потерями эксперта)**.** *Для любого эксперта $i \in I$ и любого $T \geqslant 1$*

$$M_T \leqslant -\frac{1}{\eta} \ln w_{T+1}^i = L_T^i + \frac{1}{\eta} \ln \frac{1}{w_1^i} = L_T^i + \frac{\ln N}{\eta}. \tag{2.2}$$

Доказательство. Так как $W_{T+1} = \sum_{j=1}^{N} w_{T+1}^j \geqslant w_{T+1}^i$, из (2.1) получаем первое неравенство. Остальные равенства следуют из формул $w_{T+1}^i = w_1^i \exp\left(-\eta L_T^i\right)$ и $w_1^i = 1/N$. □

Следующие вспомогательные свойства используются при переходе к переменному параметру обучения. Обозначим через m_t^η и M_T^η смешанные и кумулятивные смешанные потери алгоритма с постоянным параметром η. При сравнении разных значений η последовательность потерь экспертов и начальные веса остаются одними и теми же; веса p_t^i вычисляются с соответствующим параметром. Положим также

$$\ell_t^- := \min_{i \in I} \ell_t^i, \qquad \ell_t^+ := \max_{i \in I} \ell_t^i.$$

Лемма (Границы и монотонность смешанных потерь). *Для постоянного параметра обучения $\eta \in (0, \infty)$ выполнены следующие свойства:*

1. *На каждом шаге t*
$$\ell_t^- \leqslant m_t^\eta \leqslant \sum_{i=1}^N p_t^i \ell_t^i = \ell_t \leqslant \ell_t^+. \tag{2.3}$$

2. *Кумулятивные смешанные потери M_T^η являются невозрастающей функцией параметра обучения:*
$$M_T^\eta \geqslant M_T^\mu \qquad \text{при } 0 < \eta \leqslant \mu < \infty. \tag{2.4}$$

Доказательство. Так как $\ell_t^i \geqslant \ell_t^-$ для всех i, имеем

$$\sum_{i=1}^N p_t^i \exp\left(-\eta \ell_t^i\right) \leqslant \exp\left(-\eta \ell_t^-\right) \sum_{i=1}^N p_t^i = \exp\left(-\eta \ell_t^-\right).$$

Применяя к обеим частям функцию $x \mapsto -\eta^{-1} \ln x$, получаем $m_t^\eta \geqslant \ell_t^-$. Кроме того, $\ell_t = \sum_{i=1}^N p_t^i \ell_t^i \leqslant \ell_t^+$, поскольку $\bar{p}_t$ является вероятностным распределением.

Для доказательства неравенства $m_t^\eta \leqslant \ell_t$ воспользуемся неравенством Йенсена:

$$\varphi(\mathbb{E}X) \leqslant \mathbb{E}\varphi(X),$$

где φ — выпуклая функция, а X — случайная величина. Пусть X принимает значения ℓ_t^i с вероятностями p_t^i, $i \in I$. Применяя неравенство Йенсена к выпуклой функции $\varphi(x) = \exp(-\eta x)$, получаем

$$\exp\left(-\eta \sum_{i=1}^N p_t^i \ell_t^i\right) \leqslant \sum_{i=1}^N p_t^i \exp\left(-\eta \ell_t^i\right).$$

После логарифмирования и умножения на $-1/\eta$ это даёт

$$m_t^\eta = -\frac{1}{\eta} \ln\left(\sum_{i=1}^N p_t^i \exp\left(-\eta \ell_t^i\right)\right) \leqslant \sum_{i=1}^N p_t^i \ell_t^i = \ell_t.$$

Докажем монотонность. Пусть $0 < \eta \leqslant \mu < \infty$. Функция $x \mapsto x^{\eta/\mu}$ вогнута на $(0, \infty)$, поэтому по неравенству Йенсена

$$\sum_{i=1}^N w_1^i \exp\left(-\eta L_T^i\right) = \sum_{i=1}^N w_1^i \left(\exp\left(-\mu L_T^i\right)\right)^{\eta/\mu} \leqslant \left(\sum_{i=1}^N w_1^i \exp\left(-\mu L_T^i\right)\right)^{\eta/\mu}.$$

Используя (2.1), заключаем, что

$$M_T^\eta = -\frac{1}{\eta} \ln\left(\sum_{i=1}^N w_1^i \exp\left(-\eta L_T^i\right)\right) \geqslant -\frac{1}{\mu} \ln\left(\sum_{i=1}^N w_1^i \exp\left(-\mu L_T^i\right)\right) = M_T^\mu.$$

□

2.2 Смешивание с переменным параметром обучения

В алгоритме AdaHedge [5] параметр обучения $\eta_t \in (0, \infty)$ может меняться от шага к шагу. При этом веса вычисляются заново по кумулятивным потерям экспертов за предыдущие $t-1$ шагов:

$$w_t^i = w_1^i \exp\left(-\eta_t L_{t-1}^i\right), \qquad p_t^i = \frac{w_t^i}{W_t} = \frac{\exp\left(-\eta_t L_{t-1}^i\right)}{\sum_{j=1}^N \exp\left(-\eta_t L_{t-1}^j\right)}.$$

Здесь $w_1^i = 1/N$ и $L_0^i = 0$, поэтому $p_1^i = 1/N$.

Смешанные потери на шаге t теперь имеют вид

$$m_t = -\frac{1}{\eta_t} \ln\left(\sum_{i=1}^N p_t^i \exp\left(-\eta_t \ell_t^i\right)\right) = -\frac{1}{\eta_t} \ln\left(\frac{\sum_{i=1}^N \exp\left(-\eta_t L_t^i\right)}{\sum_{j=1}^N \exp\left(-\eta_t L_{t-1}^j\right)}\right). \tag{2.5}$$

Обозначение M_t^η сохраняем для кумулятивных смешанных потерь с одним и тем же постоянным параметром η на всех шагах. Полагая $M_0^\eta = 0$, из (2.1) и (2.5) получаем

$$m_t = M_t^{\eta_t} - M_{t-1}^{\eta_t}. \tag{2.6}$$

В то же время $M_T = \sum_{t=1}^T m_t$ обозначает кумулятивные смешанные потери алгоритма с последовательностью параметров $\eta_1, \ldots, \eta_T$.

Лемма (Оценка при невозрастающем параметре обучения)**.** *Если* $\eta_1 \geqslant \eta_2 \geqslant \cdots \geqslant \eta_T > 0$, *то*

$$M_T \leqslant M_T^{\eta_T}, \tag{2.7}$$

где правая часть соответствует постоянному параметру $\eta = \eta_T$ *на всех* T *шагах.*

Доказательство. По (2.4), из $\eta_t \geqslant \eta_{t+1}$ следует $M_t^{\eta_t} \leqslant M_t^{\eta_{t+1}}$. Поэтому, используя (2.6) и $M_0^{\eta_1} = 0$, имеем

$$M_T = \sum_{t=1}^T \left(M_t^{\eta_t} - M_{t-1}^{\eta_t}\right) = M_T^{\eta_T} + \sum_{t=1}^{T-1} \left(M_t^{\eta_t} - M_t^{\eta_{t+1}}\right) \leqslant M_T^{\eta_T}.$$

□

Наконец, объединяя (2.7), (2.1) и (2.2), для любого эксперта $i \in I$ получаем

$$M_T \leqslant M_T^{\eta_T} = -\frac{1}{\eta_T} \ln\left(\sum_{j=1}^N w_1^j \exp\left(-\eta_T L_T^j\right)\right) \leqslant L_T^i + \frac{\ln N}{\eta_T}. \tag{2.8}$$

3 Основные результаты

Рассмотрим алгоритм sAdaHedge для экспертов-специалистов, представленный в [3]. Постановка задачи такая же, как и прежде, но теперь множество экспертов разделено на два подмножества — активных и «спящих» экспертов — в этом и заключается их специализированность. Множество активных экспертов на шаге t обозначим $E_t \subset \{1, \ldots, N\}$. Потери активных экспертов определены так же, как и ранее: ℓ_t^i для эксперта i, а для спящих потери не определены. Кумулятивные потери определим следующим образом:

$$\mathcal{L}_T^i := \sum_{t: i \in E_t}^T \ell_t^i.$$

Будем использовать параметр обучения η_t, определяемый в процессе работы алгоритма. Каждому спящему эксперту $i \notin E_t$ припишем виртуальные потери, равные смешанным потерям m_t. Таким образом, расширим определение потерь, полагая $\ell_t^i = m_t$ при $i \notin E_t$.

На первый взгляд это определение содержит неизвестную величину m_t. Чтобы выразить её через потери активных экспертов, запишем

$$\begin{aligned}\exp(-\eta_t m_t) &= \sum_{i=1}^{N} p_t^i \exp(-\eta_t \ell_t^i) = \\ &= \sum_{i \in E_t} p_t^i \exp(-\eta_t \ell_t^i) + \sum_{i \notin E_t} p_t^i \exp(-\eta_t m_t) = \\ &= \sum_{i \in E_t} p_t^i \exp(-\eta_t \ell_t^i) + \left(1 - \sum_{i \in E_t} p_t^i\right) \exp(-\eta_t m_t).\end{aligned}$$

Предполагаем, что на каждом шаге $E_t \neq \varnothing$. Перенося последнее слагаемое в левую часть, получаем

$$m_t = -\frac{1}{\eta_t} \ln \left(\frac{\sum_{i \in E_t} p_t^i \exp(-\eta_t \ell_t^i)}{\sum_{j \in E_t} p_t^j} \right) = -\frac{1}{\eta_t} \ln \left(\sum_{i \in E_t} p_t^{i,E_t} \exp(-\eta_t \ell_t^i) \right), \tag{3.1}$$

где нормированные веса активных экспертов определены формулой

$$p_t^{i,E_t} = \frac{p_t^i}{\sum_{j \in E_t} p_t^j} = \frac{w_t^i}{\sum_{j \in E_t} w_t^j}, \qquad i \in E_t. \tag{3.2}$$

Потери смешивающего ПА на шаге t равны

$$\ell_t = \sum_{i \in E_t} p_t^{i,E_t} \ell_t^i.$$

Определим смешанную разность и её кумулятивное значение:

$$\delta_t := \ell_t - m_t, \qquad \Delta_T := \sum_{t=1}^{T} \delta_t.$$

По неравенству (2.3), применённому к распределению активных экспертов, $\delta_t \geqslant 0$. Поэтому последовательность Δ_T не убывает.

3.1 Алгоритм sAdaHedge

Пусть $N \geqslant 2$. Как в [3], положим

$$w_1^i = \frac{1}{N}, \quad L_0^i = 0 \quad (i \in I), \qquad H_0 = M_0 = \Delta_0 = 0.$$

Параметр обучения определяется накопленной смешанной разностью:

$$\eta_t = \begin{cases} \dfrac{\ln N}{\Delta_{t-1}}, & \Delta_{t-1} > 0, \\ \infty, & \Delta_{t-1} = 0. \end{cases} \tag{3.3}$$

Случай $\Delta_{t-1} = 0$ рассматриваем как начальное предельное соглашение алгоритма статьи; полагаем $1/\eta_t = 0$. До первого шага с ненулевой смешанной разностью расширенные кумулятивные потери всех экспертов совпадают. Поэтому на таких шагах

$$p_t^i = \frac{1}{N}, \qquad p_t^{i,E_t} = \frac{1}{|E_t|} \quad (i \in E_t), \qquad m_t = \min_{i \in E_t} \ell_t^i.$$

Как только $\Delta_{t-1} > 0$, параметр обучения конечен и положителен.

На каждом шаге $t = 1, 2, \ldots$ алгоритм выполняет следующие действия:

1. Получает множество активных экспертов E_t и определяет η_t по (3.3).

2. При $\Delta_{t-1} > 0$ вычисляет веса

$$w_t^i = w_1^i \exp(-\eta_t L_{t-1}^i), \qquad p_t^i = \frac{w_t^i}{\sum_{j=1}^N w_t^j},$$

   а затем веса активных экспертов p_t^{i,E_t} по (3.2). При $\Delta_{t-1} = 0$ использует равномерные веса, указанные выше.

3. Получает потери ℓ_t^i активных экспертов $i \in E_t$.

4. Вычисляет свои потери и смешанные потери:

$$\ell_t = \sum_{i \in E_t} p_t^{i,E_t} \ell_t^i, \qquad m_t = -\frac{1}{\eta_t} \ln \left(\sum_{i \in E_t} p_t^{i,E_t} \exp(-\eta_t \ell_t^i) \right)$$

   при конечном η_t; при $\Delta_{t-1} = 0$ полагает $m_t = \min_{i \in E_t} \ell_t^i$.

5. Приписывает спящим экспертам потери $\ell_t^i = m_t$ и обновляет кумулятивные величины:

$$\begin{aligned} L_t^i &= L_{t-1}^i + \ell_t^i, \qquad i \in I, \\ H_t &= H_{t-1} + \ell_t, \qquad M_t = M_{t-1} + m_t, \\ \delta_t &= \ell_t - m_t, \qquad \Delta_t = \Delta_{t-1} + \delta_t. \end{aligned}$$

Веса для следующего шага вычисляются заново с параметром η_{t+1}, определённым через обновлённое значение Δ_t.

3.2 Регрет относительно эксперта-специалиста

С учётом виртуальных потерь расширенные кумулятивные потери эксперта i равны

$$L_T^i = \sum_{t=1}^T \ell_t^i = \mathcal{L}_T^i + \sum_{\substack{1 \leqslant t \leqslant T \\ i \notin E_t}} m_t.$$

Как и ранее, положим $H_T = \sum_{t=1}^T \ell_t$ и $M_T = \sum_{t=1}^T m_t$. Регрет относительно расширенных потерь эксперта определяется формулой

$$R_T^i := H_T - L_T^i.$$

Из определения смешанной разности следует

$$R_T^i = \sum_{t=1}^T (m_t + \delta_t) - L_T^i = M_T - L_T^i + \Delta_T. \tag{3.4}$$

По (3.3) последовательность параметров обучения не возрастает. Применим оценку (2.8) к расширенным потерям экспертов. На начальных шагах с $\Delta_{t-1} = 0$ соответствующие экспоненциальные суммы понимаются в принятом выше предельном смысле. Получаем

$$M_T \leqslant L_T^i + \frac{\ln N}{\eta_T} = L_T^i + \Delta_{T-1} \leqslant L_T^i + \Delta_T.$$

Подставляя эту оценку в (3.4), находим $R_T^i \leqslant 2\Delta_T$.

Регрет относительно эксперта-специалиста учитывает только те шаги, на которых этот эксперт был активен:

$$\widetilde{R}_T^i := \sum_{\substack{1 \leqslant t \leqslant T \\ i \in E_t}} \ell_t - \mathcal{L}_T^i = \sum_{\substack{1 \leqslant t \leqslant T \\ i \in E_t}} (\ell_t - \ell_t^i). \tag{3.5}$$

Лемма (Сравнение регретов). *Для любого $i \in I$ и любого $T \geqslant 1$*

$$\widetilde{R}_T^i \leqslant R_T^i \leqslant 2\Delta_T. \tag{3.6}$$

Доказательство. Так как при $i \notin E_t$ имеем $\ell_t^i = m_t$, получаем

$$R_T^i = \sum_{\substack{1 \leqslant t \leqslant T \\ i \in E_t}} (\ell_t - \ell_t^i) + \sum_{\substack{1 \leqslant t \leqslant T \\ i \notin E_t}} (\ell_t - m_t) = \widetilde{R}_T^i + \sum_{\substack{1 \leqslant t \leqslant T \\ i \notin E_t}} \delta_t \geqslant \widetilde{R}_T^i.$$

Вместе с оценкой $R_T^i \leqslant 2\Delta_T$ это доказывает утверждение. □

3.3 Оценка смешанной разности через дисперсию потерь

Обозначим минимальную и максимальную потери активных экспертов через

$$\ell_t^- := \min_{i \in E_t} \ell_t^i, \qquad \ell_t^+ := \max_{i \in E_t} \ell_t^i,$$

а размах потерь на шаге t и его наибольшее значение за первые T шагов — через

$$s_t := \ell_t^+ - \ell_t^-, \qquad S_T := \max_{1 \leqslant t \leqslant T} s_t.$$

По (2.3), $m_t \in [\ell_t^-, \ell_t^+]$. Поэтому при учёте виртуальных потерь спящих экспертов значения минимума и максимума не изменяются. Кроме того, $0 \leqslant \delta_t \leqslant s_t$.

Введём дисперсию потерь относительно распределения активных экспертов и её кумулятивное значение:

$$v_t := \sum_{i \in E_t} p_t^{i, E_t} (\ell_t^i - \ell_t)^2, \qquad V_T := \sum_{t=1}^{T} v_t. \tag{3.7}$$

Эти величины используются в оценке смешанной разности из [3, лемма 6].

Лемма (Оценка смешанной разности). *При $s_t > 0$ и конечном η_t выполнено*

$$\delta_t \leqslant \frac{\exp(s_t \eta_t) - 1 - s_t \eta_t}{\eta_t s_t^2}\, v_t. \tag{3.8}$$

Если $s_t = 0$, то $\delta_t = v_t = 0$.

Доказательство. Воспользуемся неравенством Бернштейна в форме, приведённой в [1, леммы A.4–A.5, с. 361–362]: для случайной величины $X \in [0,1]$ и любого $a > 0$

$$\ln \mathbb{E} \exp\bigl(-a(X - \mathbb{E}X)\bigr) \leqslant \operatorname{Var}(X)(e^a - 1 - a).$$

Пусть $s_t > 0$. Рассмотрим случайную величину X, принимающую значения

$$\frac{\ell_t^i - \ell_t^-}{s_t} \quad \text{с вероятностями } p_t^{i,E_t}, \quad i \in E_t.$$

Тогда $X \in [0,1]$, причём

$$\mathbb{E}X = \frac{\ell_t - \ell_t^-}{s_t}, \qquad \operatorname{Var}(X) = \frac{v_t}{s_t^2}.$$

Применяя неравенство Бернштейна при $a = s_t\eta_t$ и используя (3.1), получаем

$$\begin{aligned}\eta_t\delta_t = \eta_t\ell_t + \ln\left(\sum_{i\in E_t} p_t^{i,E_t}\exp(-\eta_t\ell_t^i)\right) = \\ = \ln\left(\sum_{i\in E_t} p_t^{i,E_t}\exp\bigl(-\eta_t(\ell_t^i - \ell_t)\bigr)\right) = \ln\mathbb{E}\exp\bigl(-s_t\eta_t(X - \mathbb{E}X)\bigr) \leqslant \\ \leqslant \frac{v_t}{s_t^2}\bigl(\exp(s_t\eta_t) - 1 - s_t\eta_t\bigr).\end{aligned}$$

Деление на $\eta_t > 0$ даёт (3.8). При $s_t = 0$ все активные эксперты несут одинаковые потери, поэтому $m_t = \ell_t$ и $v_t = 0$. □

При $s_t > 0$ оценку (3.8) можно также записать в виде

$$\delta_t \leqslant \frac{g(s_t\eta_t)}{s_t}\,v_t, \qquad g(x) := \frac{e^x - 1 - x}{x}, \quad x > 0.$$

Из неё следует вспомогательное неравенство, используемое в доказательстве леммы 7 статьи [3]:

$$\frac{\delta_t}{\eta_t} \leqslant \frac{1}{2}v_t + \frac{1}{3}s_t\delta_t. \tag{3.9}$$

Покажем этот переход подробно. Если $s_t = 0$, обе части равны нулю. Пусть $s_t > 0$ и $x = s_t\eta_t$. При $0 < x < 3$ из $k! \geqslant 2\cdot 3^{k-2}$ для $k \geqslant 2$ получаем

$$e^x - 1 - x = \sum_{k=2}^{\infty}\frac{x^k}{k!} \leqslant \frac{x^2}{2}\sum_{k=0}^{\infty}\left(\frac{x}{3}\right)^k = \frac{x^2}{2(1 - x/3)}.$$

Подставляя это в (3.8), имеем

$$\delta_t \leqslant \frac{\eta_t v_t}{2(1 - s_t\eta_t/3)}.$$

Умножение на $(1 - s_t\eta_t/3)/\eta_t > 0$ даёт (3.9). Если же $x \geqslant 3$, то

$$\frac{\delta_t}{\eta_t} = \frac{s_t\delta_t}{x} \leqslant \frac{s_t\delta_t}{3} \leqslant \frac{1}{2}v_t + \frac{1}{3}s_t\delta_t.$$

На начальных шагах с $\Delta_{t-1} = 0$ левая часть (3.9) равна нулю по соглашению $1/\eta_t = 0$, поэтому это неравенство также выполнено.

Лемма (Оценка кумулятивной смешанной разности). *Для алгоритма sAdaHedge выполнено*

$$\Delta_T^2 \leqslant V_T \ln N + \left(\frac{2}{3}\ln N + 1\right) S_T \Delta_T. \tag{3.10}$$

Доказательство. Используем равенства $\Delta_t = \Delta_{t-1} + \delta_t$, $\Delta_0 = 0$ и $\Delta_{t-1} = \ln N/\eta_t$. Поскольку $0 \leqslant \delta_t \leqslant s_t$, имеем

$$\Delta_T^2 = \sum_{t=1}^{T} \left(\Delta_t^2 - \Delta_{t-1}^2\right) = \sum_{t=1}^{T} \left(2\delta_t \Delta_{t-1} + \delta_t^2\right) =$$

$$= \sum_{t=1}^{T} \left(2\ln N \frac{\delta_t}{\eta_t} + \delta_t^2\right) \leqslant 2\ln N \sum_{t=1}^{T} \frac{\delta_t}{\eta_t} + \sum_{t=1}^{T} s_t \delta_t \leqslant$$

$$\leqslant 2\ln N \sum_{t=1}^{T} \frac{\delta_t}{\eta_t} + S_T \Delta_T.$$

Теперь подставим (3.9) и воспользуемся определением V_T:

$$\Delta_T^2 \leqslant 2\ln N \sum_{t=1}^{T} \left(\frac{1}{2} v_t + \frac{1}{3} s_t \delta_t\right) + S_T \Delta_T \leqslant V_T \ln N + \left(\frac{2}{3}\ln N + 1\right) S_T \Delta_T.$$

□

3.4 Оценка регрета алгоритма sAdaHedge

Теорема (Вьюгин–Шамсутдинов [3]). *Для любого эксперта $i \in I$ и любого $T \geqslant 1$ регрет алгоритма sAdaHedge удовлетворяет оценке*

$$\widetilde{R}_T^i \leqslant 2\sqrt{V_T \ln N} + S_T \left(\frac{4}{3}\ln N + 2\right), \tag{3.11}$$

где V_T определено в (3.7), а $S_T = \max_{1 \leqslant t \leqslant T}(\ell_t^+ - \ell_t^-)$.

Доказательство. Положим

$$a := V_T \ln N \geqslant 0, \qquad b := S_T \left(\frac{2}{3}\ln N + 1\right) \geqslant 0.$$

По (3.10), $\Delta_T^2 \leqslant a + b\Delta_T$. Решая это квадратное неравенство, получаем

$$\Delta_T \leqslant \frac{b + \sqrt{b^2 + 4a}}{2} \leqslant \frac{b + b + 2\sqrt{a}}{2} = \sqrt{a} + b.$$

Следовательно, из (3.6)

$$\widetilde{R}_T^i \leqslant R_T^i \leqslant 2\Delta_T \leqslant 2\sqrt{V_T \ln N} + S_T \left(\frac{4}{3}\ln N + 2\right).$$

□

3.5 Переход от смешивания потерь к смешиванию прогнозов

Применим полученную оценку к исходной задаче прогнозирования. На каждом шаге t активные эксперты $i \in E_t$ выдают прогнозы γ_t^i. Предположим, что множество допустимых прогнозов $\mathcal{D}$ выпукло. Алгоритм вычисляет свой прогноз как

$$\gamma_t = \sum_{i \in E_t} p_t^{i,E_t} \gamma_t^i.$$

После появления исхода y_t потери активных экспертов определяются функцией потерь:

$$\ell_t^i = \ell(\gamma_t^i, y_t), \qquad i \in E_t.$$

Предположим, что $\ell(\gamma, y)$ выпукла по γ. Тогда

$$\ell(\gamma_t, y_t) \leqslant \sum_{i \in E_t} p_t^{i,E_t} \ell(\gamma_t^i, y_t) = \sum_{i \in E_t} p_t^{i,E_t} \ell_t^i = \ell_t.$$

Поэтому для каждого эксперта i суммарные потери прогнозов алгоритма на шагах его активности удовлетворяют неравенству

$$\sum_{\substack{1 \leqslant t \leqslant T \\ i \in E_t}} \ell(\gamma_t, y_t) \leqslant \sum_{\substack{1 \leqslant t \leqslant T \\ i \in E_t}} \ell_t.$$

Вычитая $\mathcal{L}_T^i$ и применяя (3.11), получаем

$$\sum_{\substack{1 \leqslant t \leqslant T \\ i \in E_t}} \bigl(\ell(\gamma_t, y_t) - \ell(\gamma_t^i, y_t)\bigr) \leqslant \widetilde{R}_T^i \leqslant 2\sqrt{V_T \ln N} + S_T \left(\frac{4}{3} \ln N + 2\right).$$

Таким образом, оценка теоремы сохраняется для регрета, вычисленного по потерям прогнозов.

4 Численные эксперименты

Рассмотрим применение алгоритма sAdaHedge к прогнозированию суточного потребления электроэнергии. Цель эксперимента — сравнить качество агрегированного прогноза с качеством отдельных экспертов и равномерного усреднения, а также сопоставить наблюдаемый регрет с оценкой (3.11). Используется схема специализации по дням недели, описанная в [3], с пятью регрессионными экспертами. Данные и конкретные настройки относятся к настоящему эксперименту; результаты на электропотреблении не являются воспроизведением численных результатов статьи о товарообороте.

4.1 Данные и подготовка временного ряда

Использован открытый набор данных *Individual Household Electric Power Consumption* из репозитория UCI [7]. Он содержит 2 075 259 минутных наблюдений электропотребления одного домохозяйства во Франции за период с 16 декабря 2006 г. по 26 ноября 2010 г. Для построения целевого ряда взята средняя за минуту активная мощность `Global_active_power`, измеряемая в кВт. Суточное потребление в кВт·ч определяется формулой

$$Y_d = \frac{1}{60} \sum_{r=1}^{1440} P_{d,r},$$

где $P_{d,r}$ — мощность в r-ю минуту календарного дня d.

Из 1442 календарных дней полностью наблюдались 1358. Остальные 84 дня, включая неполные граничные сутки, исключены из целевых наблюдений. Пропуски не заменялись нулями и не интерполировались: календарная сетка сохранялась, а значение Y_d для неполного дня считалось неизвестным. На рис. 1 видны сезонные изменения уровня потребления и отдельные резкие колебания.



Рис. 1: Исходный ряд суточного электропотребления. Разрывы соответствуют дням с неполными измерениями.

Прогноз строится на один день вперёд. В признаки входят значения потребления с лагами 1, 2, 7, 14 и 28 календарных дней; средние, стандартные отклонения и числа известных наблюдений за предыдущие 7 и 28 суток; семь индикаторов дня недели и два признака годового цикла:

$$\sin\left(\frac{2\pi(d_{\text{year}}-1)}{365{,}25}\right), \qquad \cos\left(\frac{2\pi(d_{\text{year}}-1)}{365{,}25}\right),$$

где d_{year} — номер дня в году. Все скользящие статистики вычисляются после сдвига ряда на один день; для недельного окна требуется не менее пяти известных значений, для окна длины 28 дней — не менее двадцати. Таким образом, используется 20 признаков, доступных до раскрытия прогнозируемого исхода.

Строки с неизвестной целью или отсутствующими необходимыми признаками удаляются после построения признаков на полной календарной сетке. В результате остаётся 989 наблюдений. Они разделены в хронологическом порядке на обучающую, калибровочную и тестовую части в пропорции 60%/20%/20% (табл. 1). Перемешивание наблюдений не применяется.

Таблица 1: Хронологическое разделение доступных наблюдений.

Назначение	Число дней	Начало	Конец
Обучение экспертов	593	17.01.2007	17.04.2009
Выбор активности	198	18.04.2009	29.01.2010
Тестирование	198	31.01.2010	25.11.2010

В дальнейшем шаг t означает очередной доступный тестовый день, поэтому $T = 198$. Соседние шаги не обязательно соответствуют соседним календарным датам. При прогнозировании разрешено использовать уже наблюдённое потребление предыдущих дней, в том числе тестовых. Следовательно, проводится последовательное прогнозирование на один день, а не одновременный прогноз всего тестового периода из одной начальной даты.

4.2 Эксперты и правило специализации

В качестве экспертов используются Ridge, Lasso, Bayesian Ridge, Random Forest и Gradient Boosting. Первые три метода являются линейными регрессионными моделями с различными способами регуляризации, последние два — ансамблями деревьев решений. Модели реализованы средствами библиотеки scikit-learn. Для линейных методов стандартизация признаков включена в процедуру обучения и на каждом проверочном разбиении оценивается только по его обучающей части.

Гиперпараметры выбирались по средней несимметричной абсолютной потере, определённой ниже, на трёх последовательных разбиениях внутри первых 593 наблюдений. Обучающая часть в этих разбиениях расширяется, а проверочные интервалы имеют одинаковую календарную длительность. Для Ridge перебирались коэффициенты регуляризации $\{0{,}1; 1; 10; 100\}$, для Lasso — $\{0{,}01; 0{,}1; 0{,}5; 1\}$. У Random Forest сравнивались максимальная глубина 4 и отсутствие ограничения глубины, а также минимальные размеры листа 3 и 10. У Gradient Boosting перебирались скорости обучения 0,03 и 0,07 и глубины деревьев 2 и 3. Оба ансамбля содержат по 150 деревьев; начальное значение генератора случайных чисел равно 42.

Выбраны Ridge с коэффициентом 100, Lasso с коэффициентом 0,5, Random Forest без ограничения глубины с минимальным размером листа 10 и Gradient Boosting со скоростью обучения 0,03 и глубиной 2. Bayesian Ridge использован с одной конфигурацией без перебора гиперпараметров. После выбора настроек каждый эксперт обучается на всей обучающей части и в ходе тестирования не переобучается. Отрицательные прогнозы заменяются нулём как при подборе параметров, так и при последующем прогнозировании.

Для каждого дня недели на калибровочной части вычисляются средние потери пяти экспертов. Три эксперта с наименьшими потерями объявляются активными в соответствующий день недели на всём тестовом периоде. Число активных экспертов фиксировано: $|E_t| = 3$. При равенстве потерь используется порядок перечисления моделей. Поскольку день недели известен заранее, множество E_t определяется до наблюдения y_t.

Полученное правило показано на рис. 2. Lasso активен во все дни; Ridge — во вторник, среду, пятницу, субботу и воскресенье; Bayesian Ridge — во вторник, субботу и воскресенье; Random Forest — в понедельник и четверг; Gradient Boosting — в понедельник, среду, четверг и пятницу. На тесте это даёт соответственно 198, 136, 69, 62 и 129 активных шагов. Для сравнения на всём горизонте прогнозы спящих экспертов также сохраняются, однако их фактические потери не участвуют в обновлении sAdaHedge: при сне используется виртуальная потеря m_t.

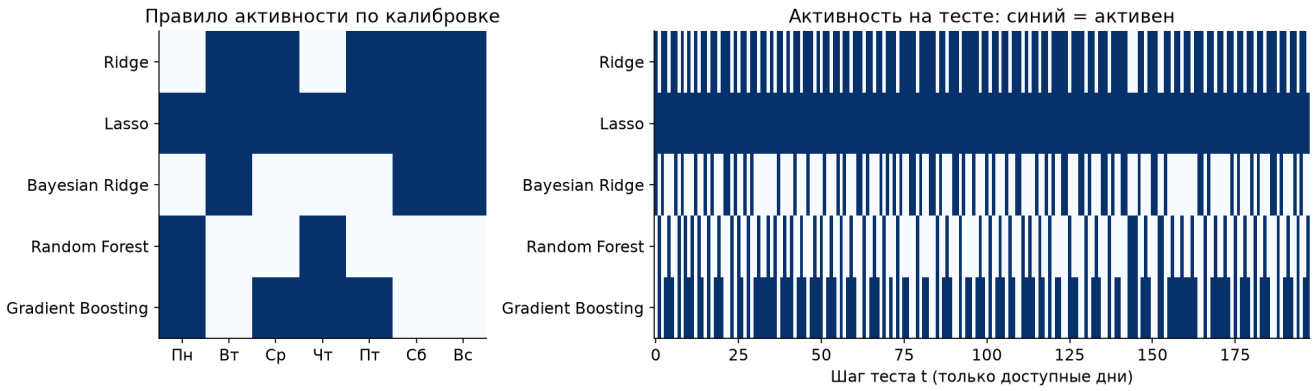


Рис. 2: Специализация экспертов: правило активности по дням недели (слева) и его применение на тесте (справа). Синим отмечена активность. На правой панели доступные дни пронумерованы с нуля.

4.3 Функция потерь и протокол сравнения

Для вычисления потерь потребление и прогнозы делятся на максимум целевой переменной обучающей части

$$C = 67{,}16203 \text{ кВт} \cdot \text{ч}.$$

Если Y_t и $\widehat{Y}_t^i$ обозначают исход и прогноз эксперта в физических единицах, то в алгоритм передаются $y_t = Y_t/C$ и $\gamma_t^i = \widehat{Y}_t^i/C$. Масштаб C не использует калибровочные или тестовые исходы; значения выше C не обрезаются. Такая нормировка задаёт единицы измерения потерь, но не гарантирует принадлежности всех будущих значений интервалу $[0, 1]$.

Используется выпуклая несимметричная абсолютная потеря

$$\ell(\gamma, y) = |\gamma - y|_+ + 2|y - \gamma|_+, \qquad |x|_+ = \max\{x, 0\}. \tag{4.1}$$

Недооценка потребления штрафуется вдвое сильнее переоценки той же величины. Коэффициенты $\lambda_1 = 1$, $\lambda_2 = 2$ задают выбранный критерий сравнения и не интерпретируются как тарифы поставщика электроэнергии.

В начале теста агрегатор запускается с равномерными начальными весами, $L_0^i = 0$ и $\Delta_0 = 0$. На каждом шаге он получает прогнозы активных экспертов, вычисляет веса по предыдущим потерям и выдаёт

$$\gamma_t = \sum_{i \in E_t} p_t^{i,E_t} \gamma_t^i.$$

Только после раскрытия y_t вычисляются потери и обновляется состояние алгоритма. Калибровочная часть используется для выбора активности и не входит в начальные кумулятивные потери агрегатора.

Сравниваются пять отдельных экспертов, sAdaHedge и два контрольных прогноза:

$$\gamma_t^{\text{act}} = \frac{1}{|E_t|} \sum_{i \in E_t} \gamma_t^i, \qquad \gamma_t^{\text{all}} = \frac{1}{N} \sum_{i=1}^{N} \gamma_t^i.$$

Первый усредняет активных экспертов, второй — всех пятерых. Для каждого метода на одних и тех же 198 днях подсчитывается суммарная потеря (4.1), а также средняя абсолютная ошибка и корень из средней квадратичной ошибки в физических единицах:

$$\text{MAE} = \frac{1}{T} \sum_{t=1}^{T} |\widehat{Y}_t - Y_t|, \qquad \text{RMSE} = \sqrt{\frac{1}{T} \sum_{t=1}^{T} (\widehat{Y}_t - Y_t)^2}.$$

Здесь $\widehat{Y}_t = C\gamma_t$ для агрегатора; для остальных методов используется их соответствующий прогноз.

Будем различать фактические кумулятивные потери прогноза

$$A_T := \sum_{t=1}^{T} \ell(\gamma_t, y_t)$$

и кумулятивную смесь потерь $H_T = \sum_{t=1}^{T} \ell_t$. По выпуклости $A_T \leqslant H_T$, но эти величины в общем случае не совпадают. В таблицах качества приведены фактические потери прогнозов, тогда как при проверке теоретической оценки отдельно учитывается смесь.

4.4 Качество прогнозирования на тестовом периоде

На рис. 3 приведены наблюдения и прогнозы для последних 90 доступных тестовых дней. Прогноз sAdaHedge следует изменениям общего уровня потребления, однако, как и прогнозы отдельных экспертов, сглаживает часть резких суточных скачков. Особенно заметны недооценённые пики осенью и переоценка ряда низких значений в августе. Разрывы линий соответствуют исключённым дням, а не нулевым прогнозам.



Рис. 3: Наблюдаемое потребление, прогнозы пяти экспертов и sAdaHedge на последних 90 доступных днях теста. Значения приведены в кВт·ч.

Итоговые показатели представлены в табл. 2; методы упорядочены по суммарной несимметричной потере. Лучший результат по этому критерию имеет Random Forest: 17,23283. Для sAdaHedge получено 17,46011, что на 0,22728, или приблизительно на 1,32%, больше. При этом sAdaHedge превосходит остальных четырёх экспертов и оба равномерных усреднения по выбранной потере. Преимущество над средним активных экспертов невелико: 0,07780, или около 0,44%.

Таблица 2: Качество прогнозов на всём тестовом горизонте ($T = 198$). Потери вычислены после нормировки; MAE и RMSE — в кВт·ч.

Метод	Суммарная потеря	MAE	RMSE
Random Forest	17,23283	3,97616	5,25696
sAdaHedge	17,46011	4,08681	5,42988
Среднее активных	17,53792	4,05079	5,41996
Gradient Boosting	17,57012	3,85351	5,33035
Среднее всех	17,88205	4,01153	5,44192
Lasso	18,37446	4,18644	5,60173
Ridge	18,83564	4,19493	5,74170
Bayesian Ridge	19,02995	4,21581	5,80568

Ранжирование зависит от метрики. Наименьшая MAE достигается у Gradient Boosting (3,85351 кВт·ч), а наименьшая RMSE — у Random Forest (5,25696 кВт·ч). Агрегатор не превосходит среднее активных экспертов по MAE и RMSE, несмотря на меньшую несимметричную потерю. Это согласуется с тем, что критерий (4.1) по-разному учитывает ошибки недооценки и переоценки.

Динамика кумулятивных потерь показана на рис. 4. В конце теста фактическая потеря агрегатора равна $A_T = 17{,}46011$, а смесь потерь — $H_T = 17{,}50171$. Разность $H_T - A_T = 0{,}04160$ соответствует выигрышу от усреднения прогнозов при выпуклой функции потерь. Кривые близки, поэтому на графике сплошная и пунктирная линии агрегатора почти совпадают.

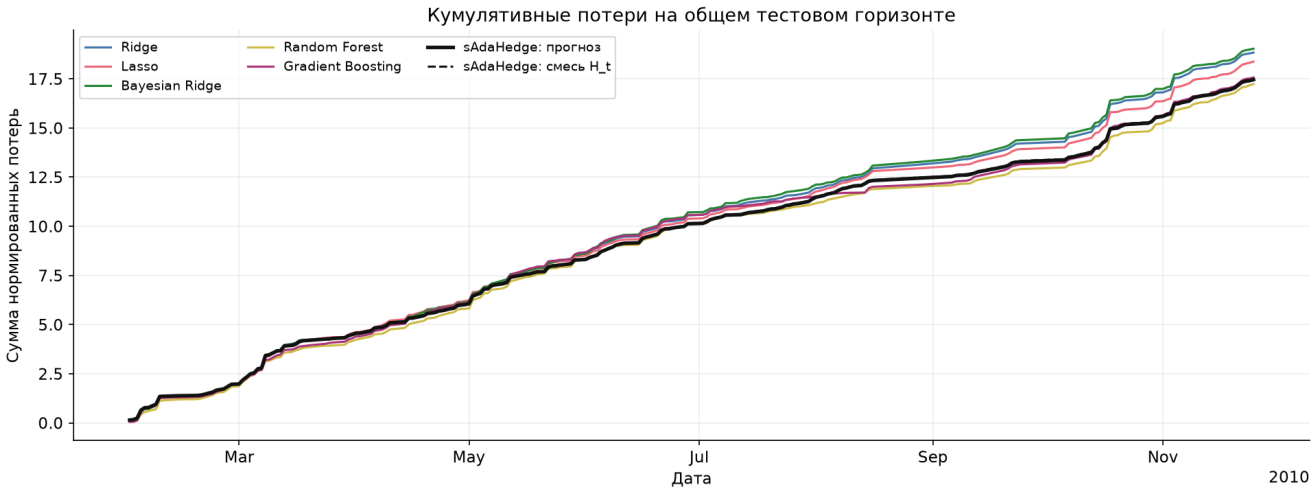


Рис. 4: Кумулятивные фактические потери экспертов и sAdaHedge на всём тесте. Чёрный пунктир показывает смесь потерь H_t, чёрная сплошная линия — потери прогнозов A_t.

4.5 Регрет на активных шагах и теоретическая граница

На днях активности каждого эксперта наряду с регретом смеси $\widetilde{R}^i_T$ из (3.5) вычислим регрет фактического прогноза:

$$\widetilde{R}^i_{T,\mathrm{pred}} := \sum_{\substack{1 \leqslant t \leqslant T \\ i \in E_t}} \bigl(\ell(\gamma_t, y_t) - \ell(\gamma^i_t, y_t)\bigr).$$

Отрицательное значение означает, что на этих днях агрегатор понёс меньшие потери, чем эксперт. Результаты приведены в табл. 3.

Таблица 3: Сравнение на днях активности каждого эксперта. $\mathcal{L}^i_T$ — фактические потери эксперта на этих днях.

Эксперт	Активных дней	$\mathcal{L}^i_T$	$\widetilde{R}^i_{T,\mathrm{pred}}$	$\widetilde{R}^i_T$
Ridge	136	11,07508	−0,01726	−0,00878
Lasso	198	18,37446	−0,91434	−0,87275
Bayesian Ridge	69	6,37518	0,07206	0,07270
Random Forest	62	6,22361	0,17868	0,21180
Gradient Boosting	129	11,06780	−0,05492	−0,01397

Регрет отрицателен для Ridge, Lasso и Gradient Boosting и положителен для Bayesian Ridge и Random Forest. Наибольший регрет смеси — 0,21180 относительно Random Forest. В конце теста получены

$$V_T \approx 0{,}02273, \qquad S_T \approx 0{,}22454, \qquad 2\Delta_T \approx 0{,}43265,$$

а правая часть теоретической оценки при $N = 5$ равна

$$B_T := 2\sqrt{V_T \ln 5} + S_T \left(\frac{4}{3}\ln 5 + 2\right) \approx 1{,}31346.$$

Все регреты специалистов меньше $2\Delta_T$ и B_T; дисперсионная граница заметно превышает наблюдаемые значения.

По сохранённой последовательности вычислений для каждого префикса $t = 1, \ldots, T$ и каждого эксперта проверена цепочка

$$\widetilde{R}^i_{t,\mathrm{pred}} \leqslant \widetilde{R}^i_t \leqslant H_t - L^i_t \leqslant 2\Delta_t \leqslant B_t$$

с численным допуском 10^{-9}; нарушений не обнаружено. Расширенные потери L^i_t включают виртуальные потери во время сна.

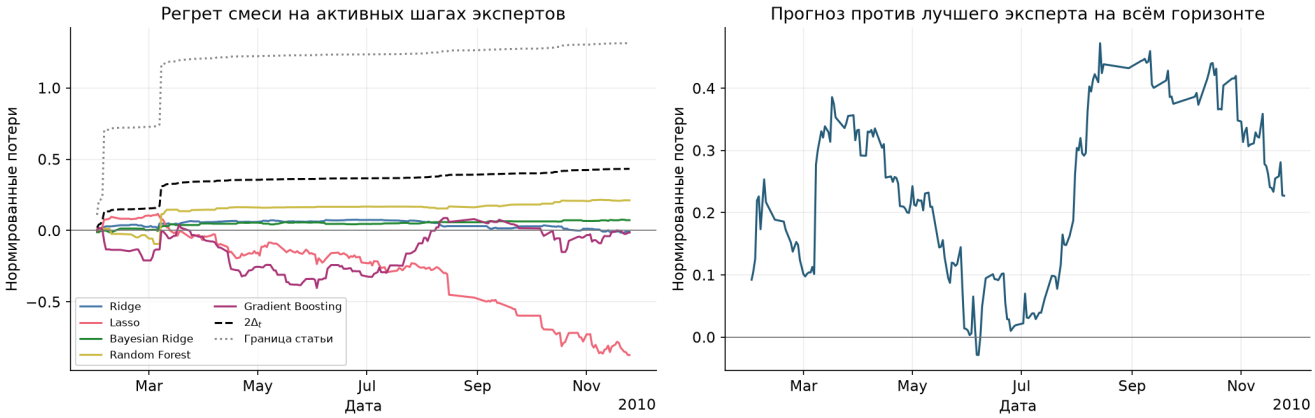


Рис. 5: Слева: регрет смеси относительно специалистов, граница $2\Delta_t$ и дисперсионная граница B_t. Справа: регрет фактического прогноза относительно лучшего фиксированного эксперта на каждом полном префиксе теста.

Левая панель рис. 5 показывает регрет на активных шагах. На правой панели приведён другой критерий:

$$R_{t,\mathrm{full}} := A_t - \min_{i \in I} \sum_{s=1}^{t} \ell(\gamma^i_s, y_s),$$

где для каждого эксперта учитываются все тестовые дни, включая дни его сна. Минимум берётся отдельно на каждом префиксе; эксперт, достигающий минимума, может меняться с t. При $t = T$ получаем $R_{T,\mathrm{full}} = 0{,}22728$. Оценка (3.11) непосредственно относится к сравнению на активных шагах и не даёт такой же гарантии для $R_{t,\mathrm{full}}$.

Попарные кумулятивные сравнения представлены на рис. 6. В пределах каждой панели все три суммы вычислены по одним и тем же дням активности соответствующего эксперта. Между панелями наборы дней и их количество различаются, поэтому сами величины кумулятивных потерь на разных панелях не служат основанием для ранжирования экспертов.

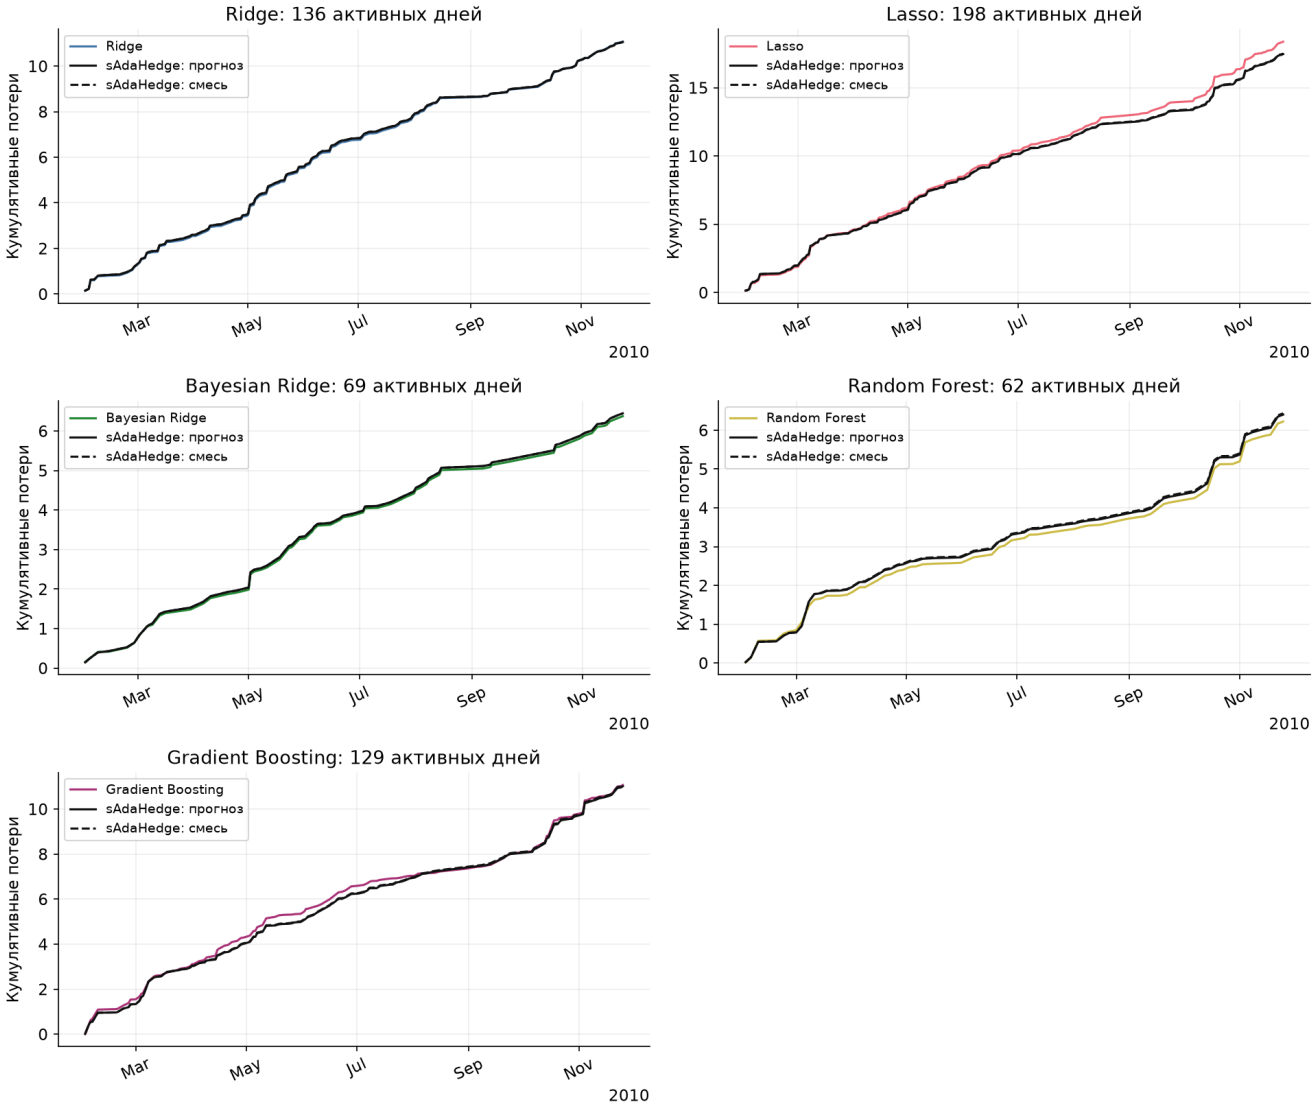


Рис. 6: Попарные сравнения на активных шагах: потери эксперта, фактические потери sAdaHedge и смесь потерь агрегатора. На каждой панели используется собственное множество дней.

4.6 Динамика весов и выводы

На рис. 7 показаны веса активных экспертов и параметр обучения. Для изображения вес спящего эксперта принимается равным нулю. Поэтому часть резких изменений верхних кривых связана с календарным переключением множества E_t и последующей нормировкой весов. Нулевой вес во время сна не означает удаления эксперта: при следующей активации он снова участвует в прогнозе.

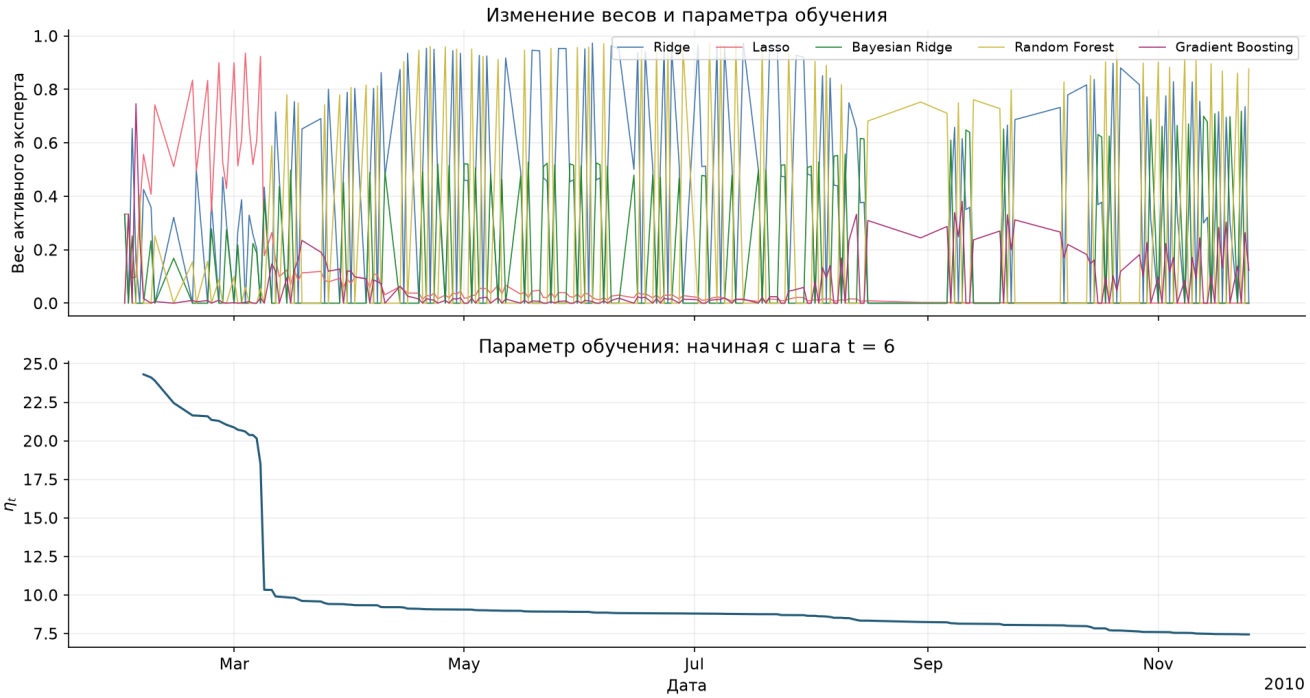


Рис. 7: Веса экспертов в прогнозе sAdaHedge (сверху) и параметр обучения η_t (снизу). Нижняя панель начинается с шестого шага; первые пять значений исключены только из изображения.

В начале теста заметную долю веса получает Lasso; далее в соответствующие дни активности существенный вес часто приходится на Ridge и Random Forest. Параметр η_t не возрастает, поскольку Δ_t не убывает. На первом шаге используется соглашение $\eta_1 = \infty$; уже на втором шаге параметр конечен и равен приблизительно 161,60. Для читаемости на нижней панели показана последовательность начиная с $t = 6$, когда $\eta_6 \approx 24{,}31$. К последнему шагу параметр снижается до $\eta_T \approx 7{,}44$.

В проведённом эксперименте sAdaHedge даёт близкое к лучшему фиксированному эксперту качество по несимметричной потере и небольшое преимущество над равномерным усреднением активных прогнозов. На активных шагах трёх из пяти экспертов регрет отрицателен; для двух остальных он положителен и остаётся в пределах теоретической оценки. При этом на всём тестовом горизонте лучшим по выбранной потере оказался Random Forest, активный в агрегаторе лишь два дня недели. Следовательно, качество фиксированного правила специализации существенно для интерпретации общего результата.

Выводы относятся к одному временному ряду, одному хронологическому разбиению и выбранным коэффициентам потерь. Небольшое преимущество перед равномерным усреднением здесь является наблюдаемым результатом; статистическая значимость этого различия не оценивалась. Дальнейшее сравнение может включать несколько последовательных тестовых периодов, другие числа активных экспертов и чувствительность к отношению λ_2/λ_1.

5 Заключение

В работе рассмотрена задача последовательного прогнозирования с советами экспертов и её обобщение на экспертов-специалистов, участвующих в прогнозе лишь на части шагов. Изложены экспоненциальное смешивание потерь, адаптивный выбор параметра обучения и алгоритм sAdaHedge. Приведено доказательство оценки его регрета относительно каждого специалиста через накопленную дисперсию и максимальный размах потерь активных экспертов. Показано, что при выпуклой функции потерь эта оценка переносится со смеси потерь на фактические потери усреднённого прогноза.

Численный эксперимент на суточном электропотреблении продемонстрировал применение схемы с пятью регрессионными экспертами и специализацией по дням недели. На 198 тестовых днях суммарная нормированная потеря sAdaHedge составила 17,46011, у лучшего фиксированного эксперта Random Forest — 17,23283, а у равномерного среднего активных экспертов — 17,53792. Следовательно, адаптивное взвешивание дало небольшое улучшение по сравнению с равномерным смешиванием, но не обеспечило превосходства над лучшим отдельным методом на всём горизонте. На днях активности трёх из пяти экспертов регрет агрегатора оказался отрицательным; теоретические неравенства для специалистов выполнены на каждом префиксе тестовой последовательности.

Полученные результаты выделяют два компонента качества: сами прогнозы экспертов и правило их допуска к агрегированию. Адаптация весов позволяет использовать различия в качестве доступных прогнозов, однако не исправляет автоматически неудачный выбор множества активных экспертов. Кроме того, адаптивный параметр обучения не означает забывания прошлых потерь: в рассмотренной схеме они накапливаются за всё время работы. Эти особенности определяют дальнейшие направления исследования.

Открытые вопросы и направления продолжения

Следующие вопросы остаются открытыми в рамках проведённого исследования. Предлагаемые изменения требуют отдельных вычислительных экспериментов, а при изменении алгоритма — проверки условий и доказательства соответствующих гарантий.

1. **Как выбирать и обновлять специализацию?** В эксперименте активность один раз определяется по калибровочной выборке и зависит только от дня недели. Можно пересматривать её по скользящему окну прошлых ошибок, учитывать сезон, праздники и доступный на момент прогноза прогноз погоды. Следует сравнить разные числа активных экспертов, включая вариант $E_t = I$, и проверить, даёт ли специализация выигрыш по сравнению с агрегированием всех пяти моделей. При сохранении протокола sAdaHedge множество E_t должно оставаться непустым и определяться до раскрытия y_t. Сама оценка относительно выбранных специалистов не гарантирует высокого качества правила, которое выбирает их активность; оценивание и обучение этого правила составляют отдельную задачу.

2. **Как ускорить адаптацию к смене режима ряда?** Если лучший эксперт меняется со временем, старые потери могут долго влиять на его вес. Возможные модификации — скользящее окно потерь, их дисконтирование, перезапуски агрегатора и небольшое перераспределение веса между экспертами. Для оценки таких изменений целесообразно перейти от всего горизонта к сравнению на отрезках, связанному с постановкой адаптивного регрета [4]. В случае специалистов естественен критерий

$$\widetilde{R}^{i}_{[a,b],\mathrm{pred}} := \sum_{\substack{a \leqslant t \leqslant b \\ i \in E_t}} \bigl(\ell(\gamma_t, y_t) - \ell(\gamma^i_t, y_t)\bigr).$$

Вопрос состоит в том, какие гарантии можно получить для него одновременно на разных временных отрезках и какова цена быстрой адаптации. Оценка на полном горизонте сама по себе этого не устанавливает; замена накопленных потерь оконными или дисконтированными требует нового анализа.

3. **Можно ли заменить бинарную активность степенью участия?** Вместо решения «активен или спит» можно задавать до наблюдения исхода коэффициент $c_t^i \in [0,1]$, отражающий пригодность эксперта для текущего контекста. Это позволяет исследовать плавный переход между режимами и уменьшить зависимость от жёсткого выбора трёх лучших моделей. Необходимо согласовать правило взвешивания с критерием качества, например с регретом

$$\sum_{t=1}^{T} c_t^i \big(\ell(\gamma_t, y_t) - \ell(\gamma_t^i, y_t)\big),$$

и определить соответствующие виртуальные потери. Простая замена индикатора активности на c_t^i в итоговой оценке без изменения доказательства недостаточна.

4. **Как улучшить и разнообразить исходные прогнозы?** Сейчас все эксперты используют один набор признаков и после обучения остаются неизменными. Можно добавить сезонный прогноз по значению неделю назад, модели с разной длиной обучающего окна и экспертов, специализирующихся на высоком или низком уровне потребления. Полезно сравнить периодическое переобучение с фиксированными моделями и согласовать обучение экспертов с несимметричной функцией потерь, которая используется для итоговой оценки. При этом обновлённая модель должна получать только уже раскрытые исходы. Основной вопрос — даёт ли расширение набора экспертов полезное разнообразие ошибок и компенсирует ли улучшение качества дополнительные вычислительные затраты.

5. **Насколько можно уточнить оценку регрета?** В эксперименте наибольший регрет смеси равен примерно 0,21180, промежуточная граница $2\Delta_T$ — 0,43265, а дисперсионная граница — 1,31346. Это мотивирует поиск более точных оценок для отдельных экспертов. Представляет интерес зависимость от числа их активных шагов и характеристик потерь именно на этих шагах, особенно для редко активных специалистов. Такая локализация не следует простой заменой V_T и S_T в доказанной формуле: состояние агрегатора меняется и во время сна рассматриваемого эксперта. Возможное продолжение включает как вывод уточнённой оценки, так и построение примеров, показывающих ограничения такого уточнения.

6. **Насколько устойчивы экспериментальные выводы?** Следует повторить сравнение на нескольких хронологических разбиениях и других рядах потребления, исследовать разные отношения λ_2/λ_1, число активных экспертов и длину калибровочного периода. Для отделения вклада компонентов нужны варианты с одинаковыми прогнозами экспертов, но разными правилами активности и взвешивания. Сравнение ошибок следует проводить по совпадающим дням и учитывать их временную зависимость при оценке неопределённости. Отдельно можно проверить влияние исключения неполных суток и сравнить его с причинным восстановлением недостающих признаков, сохраняя оценку качества на реально наблюдённых целевых значениях.

Список литературы

[1] Cesa-Bianchi N., Lugosi G. *Prediction, Learning, and Games*. Cambridge University Press, 2006. Страница книги.

[2] Freund Y., Schapire R. E. A decision-theoretic generalization of on-line learning and an application to boosting. *Journal of Computer and System Sciences*. 1997. Vol. 55, no. 1. P. 119–139. Авторская версия.

[3] V'yugin V. V., Shamsutdinov A. I. Trading-Network Order Formation with the Help of the Aggregation of Specialized Forecast Algorithms. *Journal of Communications Technology and Electronics*. 2016. Vol. 61. P. 1400–1410. https://doi.org/10.1134/S1064226916120251.

[4] Adamskiy D., Koolen W. M., Chernov A., Vovk V. A Closer Look at Adaptive Regret. *Journal of Machine Learning Research*. 2016. Vol. 17, no. 23. P. 1–21. https://www.jmlr.org/papers/v17/13-533.html.

[5] De Rooij S., Van Erven T., Grünwald P. D., Koolen W. M. Follow the Leader If You Can, Hedge If You Must. *Journal of Machine Learning Research*. 2014. Vol. 15, no. 37. P. 1281–1316. https://www.jmlr.org/papers/v15/rooij14a.html.

[6] Devaine M., Gaillard P., Goude Y., Stoltz G. Forecasting electricity consumption by aggregating specialized experts. *Machine Learning*. 2013. Vol. 90, no. 2. P. 231–260. https://doi.org/10.1007/s10994-012-5314-7.

[7] Hebrail G., Berard A. *Individual Household Electric Power Consumption* [набор данных]. UCI Machine Learning Repository, 2006. https://doi.org/10.24432/C58K54.