Адаптивное агрегирование прогнозов специализированных экспертов

Е.А. Цыбулин

31 октября 2026 г.

1 Стандартная постановка задачи и основные определения

Рассматривается задача прогнозирования временного ряда с использованием экспертных стратегий (*prediction with expert advice*). *Временной ряд* $y = (y_1, y_2, \dots)$ представляет собой последовательность элементов некоторого множества $\mathcal{Y}$, называемых исходами. В рамках данной теории строятся алгоритмы, называемые *смешивающими прогнозирующими алгоритмами (ПА)* или *агрегаторами*, объединяющие предсказания следующего исхода различных методов прогнозирования.

Экспертные стратегии (далее — *эксперты*) могут иметь совершенно разную природу — это могут быть некоторые правила, функции, алгоритмы, оценки специалистов и т.д. Каждый эксперт может быть эффективнее других на определённых участках ряда.

Классическая задача заключается в том, что в режиме онлайн на шагах $t = 1, 2, \dots$ генерируются исходы $y_1, y_2, \dots \in \mathcal{Y}$. В каждый момент времени $t \in \mathbb{N}$ агрегатор, зная предыдущие исходы, а также предсказания γ_t^i, $i = 1, \dots, N$ из множества допустимых прогнозов $\mathcal{D}$ конечного числа экспертов из множества $I = \{1, \dots, N\}$, делает свой прогноз $\gamma_t \in \mathcal{D}$. После того, как становится известен следующий исход y_t, каждый эксперт, а также агрегатор оцениваются величиной потерь.

Потери на шаге t равны значению *функции потерь (лосс)*

$$\ell : \mathcal{D} \times \mathcal{Y} \to [0, +\infty)$$

на паре (γ_t, y_t) для агрегатора и на паре (γ_t^i, y_t) — для эксперта i. Примеры функций потерь:

$$\ell(\gamma, y) = \lambda_1 |\gamma - y|_+ + \lambda_2 |y - \gamma|_+,$$

где $|x|_+ := \max(x, 0)$, $\lambda_1, \lambda_2 > 0$. Такая несимметричная абсолютная функция потерь штрафует заниженные прогнозы сильнее, чем завышенные при условии, что $\lambda_2 > \lambda_1$. Другие примеры:

$$\ell(\gamma, y) = (\gamma - y)^2, \quad \ell(\gamma, y) = [\![\gamma \neq y]\!],$$

где $[\![x]\!]$ равно 1, если выражение x в скобках истинно, и 0 — иначе. Также имеют место суммарные (кумулятивные) потери на отрезке $t = 1, \dots, T$:

$$L_T := \sum_{t=1}^{T} \ell(\gamma_t, y_t), \quad L_T^i := \sum_{t=1}^{T} \ell(\gamma_t^i, y_t).$$

Наша цель — получить смешивающий ПА, который выдаёт ответы, наиболее близкие к ответам наилучшего эксперта. Поскольку происхождение исходов нам неизвестно (природа

временного ряда необязательно имеет вероятностный характер, поэтому исходы могут иметь как стохастическую природу, так и детерминированную или вообще враждебную по отношению к прогнозирующему алгоритму), то основной гарантией эффективности алгоритма является *регрет относительно лучшего фиксированного эксперта*:

$$R_T := L_T - \min_{1 \leqslant i \leqslant N} L_T^i.$$

2 Смешивание потерь

Рассмотрим пример задачи, которую предгалагается решить: агрегатор имеет набор друзей, которые последовательно делают ставки и выигрывают или проигрывают на каждом шаге определённую сумму. Агрегатор, располагая некоторым количеством денег, хочет распределить их между друзьями так, чтобы получить максимальный выигрыш.

Определим понятие вероятностного распределения на множестве $I = \{1, \ldots, N\}$, которое представляет собой произвольный вектор $\bar{p}_t = (p^1, \ldots, p^N)$, где $\sum\limits_{i=1}^{N} p^i = 1$, $p^i \geqslant 0$, $i = 1, \ldots, N$. Множество всех вероятностных распределений будем обозначать I^Δ.

Рассмотрим задачу смешивания потерь: пусть на каждом шаге известны только потери экспертов (конкретная функция потерь может отсутствовать). На каждом шаге $t = 1, 2, \ldots$:

1. агрегатор находит вектор распределения экспертов $\bar{p}_t = (p^1, \ldots, p^N) \in I^\Delta$;
2. эксперты объявляют потери ℓ_t^i, также пусть $\bar{\ell}_t = (\ell_t^1, \ldots, \ell_t^N)$;
3. агрегатор подсчитывает свои потери $\ell_t = (\bar{p}_t \cdot \bar{\ell}_t) := \sum\limits_{i=1}^{N} p_t^i \cdot \ell_t^i$;
4. агрегатор пересчитывает вектор распределения.

Предполагаем, что потери экспертов ограничены, например, $\ell_t^i \in [0, 1]$ $\forall t \in \mathbb{N}$, $\forall i \in \{1, \ldots, N\}$. Определим кумулятивные потери:

$$L_T = \sum_{i=1}^{T} (\bar{p}_t \cdot \bar{\ell}_t), \quad L_T^i = \sum_{i=1}^{T} \ell_t^i.$$

Задача агрегатора заключается в подборе вектора распределения так, чтобы минимизировать величину

$$R_T = L_T - \min_{1 \leqslant i \leqslant N} L_T^i$$

2.1 Экспоненциальное смешивание потерь

Для решения задачи рассмотрим алгоритм $Hedge(\eta)$, который имеет входные параметры η — параметр обучения и начальный набор весов экспертов $(w_1^1, \ldots, w_1^N)$. Пусть веса экспертов в начальный момент времени определены равномерным распределением, то есть $w_1^i = \frac{1}{N}$, $\forall i \in I$. Для моментов времени $t = 1, 2, \ldots$:

1. алгоритм вычисляет $\bar{p}_t = \frac{\bar{w}_t}{\sum\limits_{i=1}^{N} w_t^i}$ — вектор распределения экспертов;
2. эксперты объявляют свои потери ℓ_t^i, также пусть $\bar{\ell}_t = (\ell_t^1, \ldots, \ell_t^N)$;
3. алгоритм подсчитывает свои потери $\ell_t = (\bar{p}_t \cdot \bar{\ell}_t) := \sum\limits_{i=1}^{N} p_t^i \cdot \ell_t^i$;

4. алгоритм пересчитывает веса экспертов

$$w_{t+1}^i = w_t^i \cdot \exp\left(-\eta \ell_t^i\right).$$

Определим кумулятивные потери:

$$L_T = \sum_{t=1}^T \ell_t, \quad L_T^i = \sum_{t=1}^T \ell_t^i.$$

Легко видеть, что

$$w_t^i = w_1^i \cdot \exp\left(-\eta L_{t-1}^i\right).$$

Введём следующее понятие *смешанной потери алгоритма*:

$$m_t := -\frac{1}{\eta} \ln \left(\sum_{i=1}^N p_t^i \cdot \exp\left(-\eta \ell_t^i\right) \right).$$

Очевидным образом определяются *кумулятивные смешанные потери*:

$$M_T := \sum_{t=1}^T m_t.$$

Определим $W_t = \sum\limits_{i=1}^N w_t^i$ для всех t, тогда из определения следует, что $p_t^i = \frac{w_t^i}{W_t}$.

Лемма (Представление кумулятивных смешанных потерь)**.** *Для любого $T \geqslant 1$ выполнено*

$$M_T = -\frac{1}{\eta} \ln W_{T+1} = -\frac{1}{\eta} \ln \left(\sum_{i=1}^N w_1^i \exp\left(-\eta L_T^i\right) \right). \tag{2.1}$$

Доказательство. По правилу обновления весов

$$\sum_{i=1}^N p_t^i \exp\left(-\eta \ell_t^i\right) = \frac{1}{W_t} \sum_{i=1}^N w_t^i \exp\left(-\eta \ell_t^i\right) = \frac{W_{t+1}}{W_t}.$$

Следовательно, поскольку $W_1 = \sum_{i=1}^N w_1^i = 1$,

$$M_T = -\frac{1}{\eta} \sum_{t=1}^T \ln \frac{W_{t+1}}{W_t} = -\frac{1}{\eta} \ln \prod_{t=1}^T \frac{W_{t+1}}{W_t} = -\frac{1}{\eta} \ln \frac{W_{T+1}}{W_1} = -\frac{1}{\eta} \ln W_{T+1}.$$

Второе равенство в (2.1) следует из представления $w_{T+1}^i = w_1^i \exp\left(-\eta L_T^i\right)$. □

Лемма (Сравнение с потерями эксперта)**.** *Для любого эксперта $i \in I$ и любого $T \geqslant 1$*

$$M_T \leqslant -\frac{1}{\eta} \ln w_{T+1}^i = L_T^i + \frac{1}{\eta} \ln \frac{1}{w_1^i} = L_T^i + \frac{\ln N}{\eta}. \tag{2.2}$$

Доказательство. Так как $W_{T+1} = \sum_{j=1}^N w_{T+1}^j \geqslant w_{T+1}^i$, из (2.1) получаем первое неравенство. Остальные равенства следуют из формул $w_{T+1}^i = w_1^i \exp\left(-\eta L_T^i\right)$ и $w_1^i = 1/N$. □

Следующие вспомогательные свойства используются при переходе к переменному параметру обучения. Обозначим через m_t^η и M_T^η смешанные и кумулятивные смешанные потери алгоритма с постоянным параметром η. При сравнении разных значений η последовательность потерь экспертов и начальные веса остаются одними и теми же; веса p_t^i вычисляются с соответствующим параметром. Положим также

$$\ell_t^- := \min_{i\in I} \ell_t^i, \qquad \ell_t^+ := \max_{i\in I} \ell_t^i.$$

Лемма (Границы и монотонность смешанных потерь)**.** *Для постоянного параметра обучения $\eta \in (0,\infty)$ выполнены следующие свойства:*

1. *На каждом шаге t*
$$\ell_t^- \leqslant m_t^\eta \leqslant \sum_{i=1}^N p_t^i \ell_t^i = \ell_t \leqslant \ell_t^+. \tag{2.3}$$

2. *Кумулятивные смешанные потери M_T^η являются невозрастающей функцией параметра обучения:*
$$M_T^\eta \geqslant M_T^\mu \qquad \text{при } 0 < \eta \leqslant \mu < \infty. \tag{2.4}$$

Доказательство. Так как $\ell_t^i \geqslant \ell_t^-$ для всех i, имеем

$$\sum_{i=1}^N p_t^i \exp\left(-\eta \ell_t^i\right) \leqslant \exp\left(-\eta \ell_t^-\right) \sum_{i=1}^N p_t^i = \exp\left(-\eta \ell_t^-\right).$$

Применяя к обеим частям функцию $x \mapsto -\eta^{-1} \ln x$, получаем $m_t^\eta \geqslant \ell_t^-$. Кроме того, $\ell_t = \sum_{i=1}^N p_t^i \ell_t^i \leqslant \ell_t^+$, поскольку $\bar{p}_t$ является вероятностным распределением.

Для доказательства неравенства $m_t^\eta \leqslant \ell_t$ воспользуемся неравенством Йенсена:

$$\varphi(\mathbb{E}X) \leqslant \mathbb{E}\varphi(X),$$

где φ — выпуклая функция, а X — случайная величина. Пусть X принимает значения ℓ_t^i с вероятностями p_t^i, $i \in I$. Применяя неравенство Йенсена к выпуклой функции $\varphi(x) = \exp(-\eta x)$, получаем

$$\exp\left(-\eta \sum_{i=1}^N p_t^i \ell_t^i\right) \leqslant \sum_{i=1}^N p_t^i \exp\left(-\eta \ell_t^i\right).$$

После логарифмирования и умножения на $-1/\eta$ это даёт

$$m_t^\eta = -\frac{1}{\eta} \ln\left(\sum_{i=1}^N p_t^i \exp\left(-\eta \ell_t^i\right)\right) \leqslant \sum_{i=1}^N p_t^i \ell_t^i = \ell_t.$$

Докажем монотонность. Пусть $0 < \eta \leqslant \mu < \infty$. Функция $x \mapsto x^{\eta/\mu}$ вогнута на $(0,\infty)$, поэтому по неравенству Йенсена

$$\sum_{i=1}^N w_1^i \exp\left(-\eta L_T^i\right) = \sum_{i=1}^N w_1^i \left(\exp\left(-\mu L_T^i\right)\right)^{\eta/\mu} \leqslant \left(\sum_{i=1}^N w_1^i \exp\left(-\mu L_T^i\right)\right)^{\eta/\mu}.$$

Используя (2.1), заключаем, что

$$M_T^\eta = -\frac{1}{\eta} \ln\left(\sum_{i=1}^N w_1^i \exp\left(-\eta L_T^i\right)\right) \geqslant -\frac{1}{\mu} \ln\left(\sum_{i=1}^N w_1^i \exp\left(-\mu L_T^i\right)\right) = M_T^\mu.$$

□

2.2 Смешивание с переменным параметром обучения

В алгоритме AdaHedge [5] параметр обучения $\eta_t \in (0, \infty)$ может меняться от шага к шагу. При этом веса вычисляются заново по кумулятивным потерям экспертов за предыдущие $t-1$ шагов:

$$w_t^i = w_1^i \exp\left(-\eta_t L_{t-1}^i\right), \qquad p_t^i = \frac{w_t^i}{W_t} = \frac{\exp\left(-\eta_t L_{t-1}^i\right)}{\sum_{j=1}^N \exp\left(-\eta_t L_{t-1}^j\right)}.$$

Здесь $w_1^i = 1/N$, поэтому $p_1^i = 1/N$.

Смешанные потери на шаге t теперь имеют вид

$$m_t = -\frac{1}{\eta_t} \ln\left(\sum_{i=1}^N p_t^i \exp\left(-\eta_t \ell_t^i\right)\right) = -\frac{1}{\eta_t} \ln\left(\frac{\sum_{i=1}^N \exp\left(-\eta_t L_t^i\right)}{\sum_{j=1}^N \exp\left(-\eta_t L_{t-1}^j\right)}\right). \tag{2.5}$$

Обозначение M_t^η сохраняем для кумулятивных смешанных потерь с одним и тем же постоянным параметром η на всех шагах. Полагая $M_0^\eta = 0$, из (2.1) и (2.5) получаем

$$m_t = M_t^{\eta_t} - M_{t-1}^{\eta_t}. \tag{2.6}$$

В то же время $M_T = \sum_{t=1}^T m_t$ обозначает кумулятивные смешанные потери алгоритма с последовательностью параметров $\eta_1, \ldots, \eta_T$.

Лемма (Оценка при невозрастающем параметре обучения)**.** *Если* $\eta_1 \geqslant \eta_2 \geqslant \cdots \geqslant \eta_T > 0$, *то*

$$M_T \leqslant M_T^{\eta_T}, \tag{2.7}$$

где правая часть соответствует постоянному параметру $\eta = \eta_T$ *на всех* T *шагах.*

Доказательство. По (2.4), из $\eta_t \geqslant \eta_{t+1}$ следует $M_t^{\eta_t} \leqslant M_t^{\eta_{t+1}}$. Поэтому, используя (2.6) и $M_0^{\eta_1} = 0$, имеем

$$M_T = \sum_{t=1}^T \left(M_t^{\eta_t} - M_{t-1}^{\eta_t}\right) = M_T^{\eta_T} + \sum_{t=1}^{T-1} \left(M_t^{\eta_t} - M_t^{\eta_{t+1}}\right) \leqslant M_T^{\eta_T}.$$

□

Наконец, объединяя (2.7), (2.1) и (2.2), для любого эксперта $i \in I$ получаем

$$M_T \leqslant M_T^{\eta_T} = -\frac{1}{\eta_T} \ln\left(\sum_{j=1}^N w_1^j \exp\left(-\eta_T L_T^j\right)\right) \leqslant L_T^i + \frac{\ln N}{\eta_T}. \tag{2.8}$$

3 Основные результаты

Рассмотрим алгоритм sAdaHedge для экспертов-специалистов, представленный в [3]. Постановка задачи такая же, как и прежде, но теперь множество экспертов разделено на два подмножества — активных и «спящих» экспертов — в этом и заключается их специализированность. Множество активных экспертов на шаге t обозначим $E_t \subset \{1, \ldots, N\}$. Потери активных экспертов определены так же, как и ранее: ℓ_t^i для эксперта i, а для спящих потери не определены. Кумулятивные потери определим следующим образом:

$$\mathcal{L}_T^i := \sum_{t: i \in E_t}^T \ell_t^i.$$

Будем использовать параметр обучения η_t, определяемый в процессе работы алгоритма. Каждому спящему эксперту $i \notin E_t$ припишем виртуальные потери, равные смешанным потерям m_t. Таким образом, расширим определение потерь, полагая $\ell_t^i = m_t$ при $i \notin E_t$.

На первый взгляд это определение содержит неизвестную величину m_t. Чтобы выразить её через потери активных экспертов, запишем

$$\begin{aligned}\exp(-\eta_t m_t) &= \sum_{i=1}^{N} p_t^i \exp(-\eta_t \ell_t^i) = \\ &= \sum_{i \in E_t} p_t^i \exp(-\eta_t \ell_t^i) + \sum_{i \notin E_t} p_t^i \exp(-\eta_t m_t) = \\ &= \sum_{i \in E_t} p_t^i \exp(-\eta_t \ell_t^i) + \left(1 - \sum_{i \in E_t} p_t^i\right) \exp(-\eta_t m_t).\end{aligned}$$

Предполагаем, что на каждом шаге $E_t \neq \varnothing$. Перенося последнее слагаемое в левую часть, получаем

$$m_t = -\frac{1}{\eta_t} \ln \left(\frac{\sum_{i \in E_t} p_t^i \exp(-\eta_t \ell_t^i)}{\sum_{j \in E_t} p_t^j} \right) = -\frac{1}{\eta_t} \ln \left(\sum_{i \in E_t} p_t^{i,E_t} \exp(-\eta_t \ell_t^i) \right), \tag{3.1}$$

где нормированные веса активных экспертов определены формулой

$$p_t^{i,E_t} = \frac{p_t^i}{\sum_{j \in E_t} p_t^j}, \qquad i \in E_t. \tag{3.2}$$

Потери агрегатора на шаге t равны

$$\ell_t = \sum_{i \in E_t} p_t^{i,E_t} \ell_t^i.$$

Определим *смешанную разность* и её кумулятивное значение:

$$\delta_t := \ell_t - m_t, \qquad \Delta_T := \sum_{t=1}^{T} \delta_t.$$

По неравенству (2.3), применённому к распределению активных экспертов, $\delta_t \geqslant 0$. Поэтому последовательность Δ_T не убывает.

3.1 Алгоритм sAdaHedge

Пусть $N \geqslant 2$. Как в [3], положим

$$w_1^i = \frac{1}{N}, \quad L_0^i = 0 \quad (i \in I), \qquad L_0 = M_0 = \Delta_0 = 0,$$

где L_t — *кумулятивные потери алгоритма sAdaHedge*. Параметр обучения определяется накопленной смешанной разностью:

$$\eta_t = \begin{cases} \dfrac{\ln N}{\Delta_{t-1}}, & \Delta_{t-1} > 0, \\ \infty, & \Delta_{t-1} = 0. \end{cases} \tag{3.3}$$

Случай $\Delta_{t-1} = 0$ рассматриваем как начальное предельное соглашение алгоритма статьи; полагаем $1/\eta_t = 0$. До первого шага с ненулевой смешанной разностью расширенные кумулятивные потери всех экспертов совпадают. Поэтому на таких шагах

$$p_t^i = \frac{1}{N}, \qquad p_t^{i,E_t} = \frac{1}{|E_t|} \quad (i \in E_t), \qquad m_t = \min_{i \in E_t} \ell_t^i.$$

Как только $\Delta_{t-1} > 0$, параметр обучения конечен и положителен.

На каждом шаге $t = 1, 2, \ldots$ алгоритм выполняет следующие действия:

1. Получает множество активных экспертов E_t и определяет η_t по (3.3).
2. При $\Delta_{t-1} > 0$ вычисляет веса

   $$w_t^i = w_1^i \exp(-\eta_t L_{t-1}^i), \qquad p_t^i = \frac{w_t^i}{\sum_{j=1}^N w_t^j},$$

   а затем веса активных экспертов p_t^{i,E_t} по (3.2). При $\Delta_{t-1} = 0$ использует равномерные веса, указанные выше.
3. Получает потери ℓ_t^i активных экспертов $i \in E_t$.
4. Вычисляет свои потери и смешанные потери:

   $$\ell_t = \sum_{i \in E_t} p_t^{i,E_t} \ell_t^i, \qquad m_t = -\frac{1}{\eta_t} \ln \left(\sum_{i \in E_t} p_t^{i,E_t} \exp(-\eta_t \ell_t^i) \right)$$

   при конечном η_t; при $\Delta_{t-1} = 0$ полагает $m_t = \min_{i \in E_t} \ell_t^i$.
5. Приписывает спящим экспертам потери $\ell_t^i = m_t$ и обновляет кумулятивные величины:

   $$\begin{aligned} L_t^i &= L_{t-1}^i + \ell_t^i, \qquad i \in I, \\ L_t &= L_{t-1} + \ell_t, \qquad M_t = M_{t-1} + m_t, \\ \delta_t &= \ell_t - m_t, \qquad \Delta_t = \Delta_{t-1} + \delta_t. \end{aligned}$$

Веса для следующего шага вычисляются заново с параметром η_{t+1}, определённым через обновлённое значение Δ_t.

3.2 Регрет относительно эксперта-специалиста

С учётом виртуальных потерь расширенные кумулятивные потери эксперта i равны

$$L_T^i = \sum_{t=1}^T \ell_t^i = \mathcal{L}_T^i + \sum_{\substack{1 \leqslant t \leqslant T \\ i \notin E_t}} m_t.$$

Как и ранее, положим $L_T = \sum_{t=1}^T \ell_t$ и $M_T = \sum_{t=1}^T m_t$. Регрет относительно расширенных потерь эксперта определяется формулой

$$R_T^i := L_T - L_T^i.$$

Из определения смешанной разности следует

$$R_T^i = \sum_{t=1}^T (m_t + \delta_t) - L_T^i = M_T - L_T^i + \Delta_T. \tag{3.4}$$

По (3.3) последовательность параметров обучения не возрастает. Применим оценку (2.8) к расширенным потерям экспертов. На начальных шагах с $\Delta_{t-1} = 0$ соответствующие экспоненциальные суммы понимаются в принятом выше предельном смысле. Получаем

$$M_T \leqslant L_T^i + \frac{\ln N}{\eta_T} = L_T^i + \Delta_{T-1} \leqslant L_T^i + \Delta_T.$$

Подставляя эту оценку в (3.4), находим $R_T^i \leqslant 2\Delta_T$.

Определим ещё *регрет алгоритма sAdaHedge*, который учитывает только те шаги, на которых этот эксперт был активен:

$$\widetilde{R}_T^i := \sum_{\substack{1 \leqslant t \leqslant T \\ i \in E_t}} \ell_t - \mathcal{L}_T^i = \sum_{\substack{1 \leqslant t \leqslant T \\ i \in E_t}} (\ell_t - \ell_t^i). \tag{3.5}$$

Лемма (Сравнение регретов). *Для любого $i \in I$ и любого $T \geqslant 1$*

$$\widetilde{R}_T^i \leqslant R_T^i \leqslant 2\Delta_T. \tag{3.6}$$

Доказательство. Так как при $i \notin E_t$ имеем $\ell_t^i = m_t$, получаем

$$R_T^i = \sum_{\substack{1 \leqslant t \leqslant T \\ i \in E_t}} (\ell_t - \ell_t^i) + \sum_{\substack{1 \leqslant t \leqslant T \\ i \notin E_t}} (\ell_t - m_t) = \widetilde{R}_T^i + \sum_{\substack{1 \leqslant t \leqslant T \\ i \notin E_t}} \delta_t \geqslant \widetilde{R}_T^i.$$

Вместе с оценкой $R_T^i \leqslant 2\Delta_T$ это доказывает утверждение. □

3.3 Оценка смешанной разности через дисперсию потерь

Обозначим минимальную и максимальную потери активных экспертов через

$$\ell_t^- := \min_{i \in E_t} \ell_t^i, \qquad \ell_t^+ := \max_{i \in E_t} \ell_t^i,$$

а размах потерь на шаге t и его наибольшее значение за первые T шагов — через

$$s_t := \ell_t^+ - \ell_t^-, \qquad S_T := \max_{1 \leqslant t \leqslant T} s_t.$$

По (2.3), $m_t \in [\ell_t^-, \ell_t^+]$. Поэтому при учёте виртуальных потерь спящих экспертов значения минимума и максимума не изменяются. Кроме того, $0 \leqslant \delta_t \leqslant s_t$.

Введём дисперсию потерь относительно распределения активных экспертов и её кумулятивное значение:

$$v_t := \sum_{i \in E_t} p_t^{i, E_t} (\ell_t^i - \ell_t)^2, \qquad V_T := \sum_{t=1}^{T} v_t. \tag{3.7}$$

Эти величины используются в оценке смешанной разности из [3, лемма 6].

Лемма (Оценка смешанной разности). *При $s_t > 0$ и конечном η_t выполнено*

$$\delta_t \leqslant \frac{\exp(s_t \eta_t) - 1 - s_t \eta_t}{\eta_t s_t^2} \, v_t. \tag{3.8}$$

Если $s_t = 0$, то $\delta_t = v_t = 0$.

Доказательство. Воспользуемся неравенством Бернштейна в форме, приведённой в [1, леммы A.4–A.5, с. 361–362]: для случайной величины $X \in [0,1]$ и любого $a > 0$

$$\ln \mathbb{E} \exp\bigl(-a(X - \mathbb{E}X)\bigr) \leqslant \mathbb{D}(X)(e^a - 1 - a).$$

Пусть $s_t > 0$. Рассмотрим случайную величину X, принимающую значения

$$\frac{\ell_t^i - \ell_t^-}{s_t} \quad \text{с вероятностями } p_t^{i,E_t}, \quad i \in E_t.$$

Тогда $X \in [0,1]$, причём

$$\mathbb{E}X = \frac{\ell_t - \ell_t^-}{s_t}, \qquad \mathbb{D}(X) = \frac{v_t}{s_t^2}.$$

Применяя неравенство Бернштейна при $a = s_t\eta_t$ и используя (3.1), получаем

$$\begin{aligned}\eta_t\delta_t = \eta_t\ell_t + \ln\left(\sum_{i\in E_t} p_t^{i,E_t}\exp(-\eta_t\ell_t^i)\right) = \\ = \ln\left(\sum_{i\in E_t} p_t^{i,E_t}\exp\bigl(-\eta_t(\ell_t^i - \ell_t)\bigr)\right) = \ln\mathbb{E}\exp\bigl(-s_t\eta_t(X - \mathbb{E}X)\bigr) \leqslant \\ \leqslant \frac{v_t}{s_t^2}\bigl(\exp(s_t\eta_t) - 1 - s_t\eta_t\bigr).\end{aligned}$$

Деление на $\eta_t > 0$ даёт (3.8). При $s_t = 0$ все активные эксперты несут одинаковые потери, поэтому $m_t = \ell_t$ и $v_t = 0$. □

При $s_t > 0$ оценку (3.8) можно также записать в виде

$$\delta_t \leqslant \frac{g(s_t\eta_t)}{s_t}\,v_t, \qquad g(x) := \frac{e^x - 1 - x}{x}, \quad x > 0.$$

Из неё следует вспомогательное неравенство, используемое в следующей лемме:

$$\frac{\delta_t}{\eta_t} \leqslant \frac{1}{2}v_t + \frac{1}{3}s_t\delta_t. \tag{3.9}$$

Покажем этот переход подробно. Если $s_t = 0$, обе части равны нулю. Пусть $s_t > 0$ и $x = s_t\eta_t$. При $0 < x < 3$ из $k! \geqslant 2\cdot 3^{k-2}$ для $k \geqslant 2$ получаем

$$e^x - 1 - x = \sum_{k=2}^{\infty}\frac{x^k}{k!} \leqslant \frac{x^2}{2}\sum_{k=0}^{\infty}\left(\frac{x}{3}\right)^k = \frac{x^2}{2(1 - x/3)}.$$

Подставляя это в (3.8), имеем

$$\delta_t \leqslant \frac{\eta_t v_t}{2(1 - s_t\eta_t/3)}.$$

Умножение на $(1 - s_t\eta_t/3)/\eta_t > 0$ даёт (3.9). Если же $x \geqslant 3$, то

$$\frac{\delta_t}{\eta_t} = \frac{s_t\delta_t}{x} \leqslant \frac{s_t\delta_t}{3} \leqslant \frac{1}{2}v_t + \frac{1}{3}s_t\delta_t.$$

На начальных шагах с $\Delta_{t-1} = 0$ левая часть (3.9) равна нулю по соглашению $1/\eta_t = 0$, поэтому это неравенство также выполнено.

Лемма (Оценка кумулятивной смешанной разности). *Для алгоритма sAdaHedge выполнено*

$$\Delta_T^2 \leqslant V_T \ln N + \left(\frac{2}{3}\ln N + 1\right) S_T \Delta_T. \tag{3.10}$$

Доказательство. Используем равенства $\Delta_t = \Delta_{t-1} + \delta_t$, $\Delta_0 = 0$ и $\Delta_{t-1} = \ln N/\eta_t$. Поскольку $0 \leqslant \delta_t \leqslant s_t$, имеем

$$\Delta_T^2 = \sum_{t=1}^{T} \left(\Delta_t^2 - \Delta_{t-1}^2\right) = \sum_{t=1}^{T} \left(2\delta_t \Delta_{t-1} + \delta_t^2\right) =$$

$$= \sum_{t=1}^{T} \left(2\ln N \frac{\delta_t}{\eta_t} + \delta_t^2\right) \leqslant 2\ln N \sum_{t=1}^{T} \frac{\delta_t}{\eta_t} + \sum_{t=1}^{T} s_t \delta_t \leqslant$$

$$\leqslant 2\ln N \sum_{t=1}^{T} \frac{\delta_t}{\eta_t} + S_T \Delta_T.$$

Теперь подставим (3.9) и воспользуемся определением V_T:

$$\Delta_T^2 \leqslant 2\ln N \sum_{t=1}^{T} \left(\frac{1}{2} v_t + \frac{1}{3} s_t \delta_t\right) + S_T \Delta_T \leqslant V_T \ln N + \left(\frac{2}{3}\ln N + 1\right) S_T \Delta_T.$$

□

3.4 Оценка регрета алгоритма sAdaHedge

Теорема (Вьюгин–Шамсутдинов [3]). *Для любого эксперта $i \in I$ и любого $T \geqslant 1$ регрет алгоритма sAdaHedge удовлетворяет оценке*

$$\widetilde{R}_T^i \leqslant 2\sqrt{V_T \ln N} + S_T \left(\frac{4}{3}\ln N + 2\right), \tag{3.11}$$

где V_T определено в (3.7), а $S_T = \max_{1 \leqslant t \leqslant T}(\ell_t^+ - \ell_t^-)$.

Доказательство. Положим

$$a := V_T \ln N \geqslant 0, \qquad b := S_T \left(\frac{2}{3}\ln N + 1\right) \geqslant 0.$$

По (3.10), $\Delta_T^2 \leqslant a + b\Delta_T$. Решая это квадратное неравенство, получаем

$$\Delta_T \leqslant \frac{b + \sqrt{b^2 + 4a}}{2} \leqslant \frac{b + b + 2\sqrt{a}}{2} = \sqrt{a} + b.$$

Следовательно, из (3.6)

$$\widetilde{R}_T^i \leqslant R_T^i \leqslant 2\Delta_T \leqslant 2\sqrt{V_T \ln N} + S_T \left(\frac{4}{3}\ln N + 2\right).$$

□

Преимущество данной теоремы заключается ещё и в отстуствии ограничений на значения потерь. Однако если потери ограничены на отрезке, то верно следующее

Следствие. *Если $s_t \leqslant 1$ для всех $t = 1, \dots, T$, то $V_T \leqslant T/4$, $S_T \leqslant 1$ и для любого эксперта $i \in I$*

$$\widetilde{R}_T^i \leqslant \sqrt{T \ln N} + \frac{4}{3} \ln N + 2 = O\Big(\sqrt{T \ln N} + \ln N\Big).$$

В частности, это верно, если все потери активных экспертов принадлежат отрезку $[0, 1]$.

Доказательство. Оценим дисперсию через размах потерь. Поскольку $\ell_t = \sum_{i \in E_t} p_t^{i,E_t} \ell_t^i$ и $\sum_{i \in E_t} p_t^{i,E_t} = 1$, разложение квадрата даёт

$$\begin{aligned} v_t &= \sum_{i \in E_t} p_t^{i,E_t} \left(\ell_t^i - \frac{\ell_t^- + \ell_t^+}{2}\right)^2 - \left(\ell_t - \frac{\ell_t^- + \ell_t^+}{2}\right)^2 \\ &\leqslant \sum_{i \in E_t} p_t^{i,E_t} \left(\ell_t^i - \frac{\ell_t^- + \ell_t^+}{2}\right)^2 \leqslant \frac{s_t^2}{4}. \end{aligned}$$

Последнее неравенство следует из того, что расстояние от любой потери $\ell_t^i \in [\ell_t^-, \ell_t^+]$ до середины этого отрезка не превосходит $s_t/2$. Таким образом, при $s_t \leqslant 1$ имеем

$$V_T = \sum_{t=1}^{T} v_t \leqslant \frac{1}{4} \sum_{t=1}^{T} s_t^2 \leqslant \frac{T}{4}, \qquad S_T = \max_{1 \leqslant t \leqslant T} s_t \leqslant 1.$$

Подстановка этих оценок в (3.11) завершает доказательство. При $N \geqslant 2$ постоянное слагаемое 2 поглощается членом $O(\ln N)$. □

3.5 Переход от смешивания потерь к смешиванию прогнозов

Применим полученную оценку к исходной задаче прогнозирования. На каждом шаге t активные эксперты $i \in E_t$ выдают прогнозы γ_t^i. Предположим, что множество допустимых прогнозов $\mathcal{D}$ выпукло. Алгоритм вычисляет свой прогноз как

$$\gamma_t = \sum_{i \in E_t} p_t^{i,E_t} \gamma_t^i.$$

После появления исхода y_t потери активных экспертов определяются функцией потерь:

$$\ell_t^i = \ell(\gamma_t^i, y_t), \qquad i \in E_t.$$

Предположим, что $\ell(\gamma, y)$ выпукла по γ. Тогда

$$\ell(\gamma_t, y_t) \leqslant \sum_{i \in E_t} p_t^{i,E_t} \ell(\gamma_t^i, y_t) = \sum_{i \in E_t} p_t^{i,E_t} \ell_t^i = \ell_t.$$

Поэтому для каждого эксперта i суммарные потери прогнозов алгоритма на шагах его активности удовлетворяют неравенству

$$\sum_{\substack{1 \leqslant t \leqslant T \\ i \in E_t}} \ell(\gamma_t, y_t) \leqslant \sum_{\substack{1 \leqslant t \leqslant T \\ i \in E_t}} \ell_t.$$

Вычитая $\mathcal{L}_T^i$ и применяя (3.11), получаем

$$\sum_{\substack{1 \leqslant t \leqslant T \\ i \in E_t}} \big(\ell(\gamma_t, y_t) - \ell(\gamma_t^i, y_t)\big) \leqslant \widetilde{R}_T^i \leqslant 2\sqrt{V_T \ln N} + S_T \left(\frac{4}{3} \ln N + 2\right).$$

Таким образом, оценка теоремы сохраняется для регрета, вычисленного по потерям прогнозов.

4 Численные эксперименты

Рассмотрим применение алгоритма sAdaHedge к прогнозированию суточного потребления электроэнергии. Цель эксперимента — сравнить качество агрегированного прогноза с качеством отдельных экспертов и равномерного усреднения, а также сопоставить наблюдаемый регрет с оценкой (3.11). Используется схема специализации по дням недели, описанная в [3], с пятью регрессионными экспертами.

4.1 Данные и подготовка временного ряда

Использован открытый набор данных *Individual Household Electric Power Consumption* из репозитория UCI [7]. Он содержит 2 075 259 минутных наблюдений электропотребления одного домохозяйства во Франции за период с 16 декабря 2006 г. по 26 ноября 2010 г. Для построения целевого ряда взята средняя за минуту активная мощность `Global_active_power`, измеряемая в кВт. Суточное потребление в кВт·ч определяется формулой

$$Y_d = \frac{1}{60} \sum_{r=1}^{1440} P_{d,r},$$

где $P_{d,r}$ — мощность в r-ю минуту календарного дня d.

Из 1442 календарных дней полностью наблюдались 1358. Остальные 84 дня, включая неполные граничные сутки, исключены из целевых наблюдений. Пропуски не заменялись нулями и не интерполировались: календарная сетка сохранялась, а значение Y_d для неполного дня считалось неизвестным. На рис. 1 видны сезонные изменения уровня потребления и отдельные резкие колебания.



Рис. 1: Исходный ряд суточного электропотребления. Разрывы соответствуют дням с неполными измерениями.

Прогноз строится на один день вперёд. В признаки входят значения потребления с лагами 1, 2, 7, 14 и 28 календарных дней; средние, стандартные отклонения и числа известных наблюдений за предыдущие 7 и 28 суток; семь индикаторов дня недели и два признака годового цикла:

$$\sin\left(\frac{2\pi(d_{\text{year}}-1)}{365{,}25}\right), \qquad \cos\left(\frac{2\pi(d_{\text{year}}-1)}{365{,}25}\right),$$

где d_{year} — номер дня в году. Все скользящие статистики вычисляются после сдвига ряда на один день; для недельного окна требуется не менее пяти известных значений, для окна

длины 28 дней — не менее двадцати. Таким образом, используется 20 признаков, доступных до раскрытия прогнозируемого исхода.

Строки с отсутствующими необходимыми признаками удаляются после построения признаков на полной календарной сетке. В результате остаётся 989 наблюдений. Они разделены в хронологическом порядке на обучающую, калибровочную и тестовую части в пропорции 60%/20%/20%. Перемешивание наблюдений не применяется.

В дальнейшем шаг t означает очередной доступный тестовый день, поэтому $T = 198$. Соседние шаги не обязательно соответствуют соседним календарным датам. При прогнозировании разрешено использовать уже известное потребление предыдущих дней, в том числе тестовых.

4.2 Эксперты и правило специализации

В качестве экспертов используются Ridge, Lasso, Bayesian Ridge, Random Forest и Gradient Boosting. Первые три метода являются линейными регрессионными моделями с различными способами регуляризации, последние два — ансамблями деревьев решений. Модели реализованы средствами библиотеки scikit-learn. Для линейных методов стандартизация признаков включена в процедуру обучения и на каждом проверочном разбиении оценивается только по его обучающей части.

Гиперпараметры выбирались по средней несимметричной абсолютной потере, определённой ниже, на трёх последовательных разбиениях внутри первых 593 наблюдений. Обучающая часть в этих разбиениях расширяется, а проверочные интервалы имеют одинаковую календарную длительность.

Выбраны Ridge с коэффициентом 100, Lasso с коэффициентом 0,5, Random Forest без ограничения глубины с минимальным размером листа 10 и Gradient Boosting со скоростью обучения 0,03 и глубиной 2. Bayesian Ridge использован с одной конфигурацией без перебора гиперпараметров. После выбора настроек каждый эксперт обучается на всей обучающей части и в ходе тестирования не переобучается. Отрицательные прогнозы заменяются нулём как при подборе параметров, так и при последующем прогнозировании.

Для каждого дня недели на калибровочной части вычисляются средние потери пяти экспертов. Три эксперта с наименьшими потерями объявляются активными в соответствующий день недели на всём тестовом периоде. Число активных экспертов фиксировано: $|E_t| = 3$. При равенстве потерь используется порядок перечисления моделей. Поскольку день недели известен заранее, множество E_t определяется до наблюдения y_t.

Полученное правило показано на рис. 2. Lasso активен во все дни; Ridge — во вторник, среду, пятницу, субботу и воскресенье; Bayesian Ridge — во вторник, субботу и воскресенье; Random Forest — в понедельник и четверг; Gradient Boosting — в понедельник, среду, четверг и пятницу. На тесте это даёт соответственно 198, 136, 69, 62 и 129 активных шагов. Для сравнения на всём горизонте прогнозы спящих экспертов также сохраняются, однако их фактические потери не участвуют в обновлении sAdaHedge: при сне используется виртуальная потеря m_t.

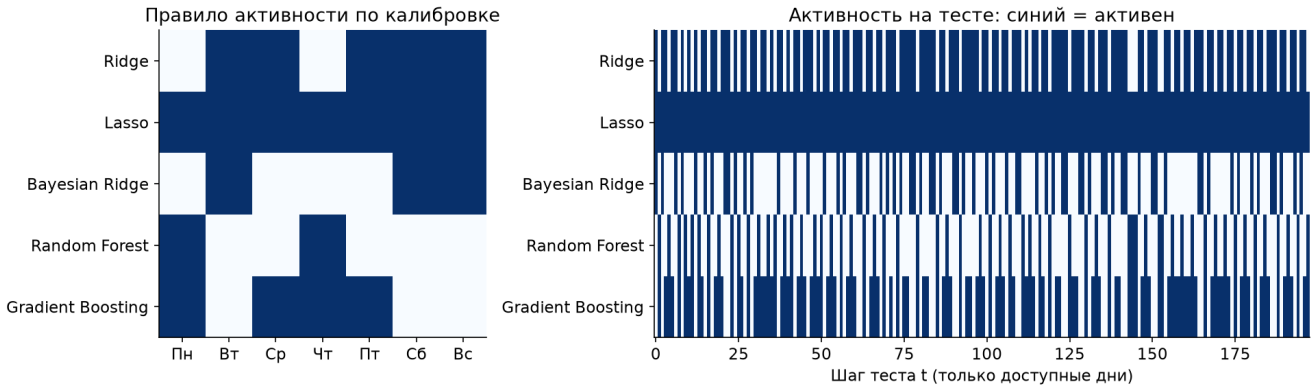


Рис. 2: Специализация экспертов: правило активности по дням недели (слева) и его применение на тесте (справа). Синим отмечена активность. На правой панели доступные дни пронумерованы с нуля.

4.3 Функция потерь и протокол сравнения

Используется выпуклая несимметричная абсолютная потеря

$$\ell(\gamma, y) = |\gamma - y|_+ + 2|y - \gamma|_+, \qquad |x|_+ = \max\{x, 0\}. \tag{4.1}$$

Недооценка потребления штрафуется вдвое сильнее переоценки той же величины. Коэффициенты $\lambda_1 = 1$, $\lambda_2 = 2$ задают выбранный критерий сравнения и не интерпретируются как тарифы поставщика электроэнергии.

В начале теста агрегатор запускается с равномерными начальными весами, $L_0^i = 0$ и $\Delta_0 = 0$. На каждом шаге он получает прогнозы активных экспертов, вычисляет веса по предыдущим потерям и выдаёт

$$\gamma_t = \sum_{i \in E_t} p_t^{i,E_t} \gamma_t^i.$$

Только после раскрытия y_t вычисляются потери и обновляется состояние алгоритма. Калибровочная часть используется для выбора активности и не входит в начальные кумулятивные потери агрегатора.

Сравниваются пять отдельных экспертов, sAdaHedge и два контрольных прогноза:

$$\gamma_t^{\text{act}} = \frac{1}{|E_t|} \sum_{i \in E_t} \gamma_t^i, \qquad \gamma_t^{\text{all}} = \frac{1}{N} \sum_{i=1}^{N} \gamma_t^i.$$

Первый усредняет активных экспертов, второй — всех пятерых. Для каждого метода на одних и тех же 198 днях подсчитывается суммарная потеря (4.1), а также средняя абсолютная ошибка и корень из средней квадратичной ошибки в физических единицах:

$$\text{MAE} = \frac{1}{T} \sum_{t=1}^{T} |y_t - \gamma_t|, \qquad \text{RMSE} = \sqrt{\frac{1}{T} \sum_{t=1}^{T} (y_t - \gamma_t)^2}.$$

Качество агрегатора оценивается по фактическим потерям выданного прогноза:

$$A_T := \sum_{t=1}^{T} \ell(\gamma_t, y_t).$$

В таблицах, графиках и попарных сравнениях используются значения $\ell(\gamma_t, y_t)$, вычисленные для самого прогноза sAdaHedge.

4.4 Качество прогнозирования на тестовом периоде

На рис. 3 приведены наблюдения и прогнозы для последних 90 доступных тестовых дней. Прогноз sAdaHedge следует изменениям общего уровня потребления, однако, как и прогнозы отдельных экспертов, сглаживает часть резких суточных скачков. Особенно заметны недооценённые пики осенью и переоценка ряда низких значений в августе. Разрывы линий соответствуют исключённым дням, а не нулевым прогнозам.



Рис. 3: Наблюдаемое потребление, прогнозы пяти экспертов и sAdaHedge на последних 90 доступных днях теста. Значения приведены в кВт·ч.

Итоговые показатели представлены в табл. 1; методы упорядочены по суммарной несимметричной потере. Лучший результат по этому критерию имеет Random Forest: 17,23283. Для sAdaHedge получено 17,46011, что на 0,22728, или приблизительно на 1,32%, больше. При этом sAdaHedge превосходит остальных четырёх экспертов и оба равномерных усреднения по выбранной потере. Преимущество над средним активных экспертов невелико: 0,07780, или около 0,44%.

Таблица 1: Качество прогнозов на всём тестовом горизонте ($T = 198$). Потери вычислены после нормировки; MAE и RMSE — в кВт·ч.

Метод	Суммарная потеря	MAE	RMSE
Random Forest	17,23283	3,97616	5,25696
sAdaHedge	17,46011	4,08681	5,42988
Среднее активных	17,53792	4,05079	5,41996
Gradient Boosting	17,57012	3,85351	5,33035
Среднее всех	17,88205	4,01153	5,44192
Lasso	18,37446	4,18644	5,60173
Ridge	18,83564	4,19493	5,74170
Bayesian Ridge	19,02995	4,21581	5,80568

Ранжирование зависит от метрики. Наименьшая MAE достигается у Gradient Boosting (3,85351 кВт·ч), а наименьшая RMSE — у Random Forest (5,25696 кВт·ч). Агрегатор не превосходит среднее активных экспертов по MAE и RMSE, несмотря на меньшую несимметричную потерю. Это согласуется с тем, что критерий (4.1) по-разному учитывает ошибки недооценки и переоценки.

Динамика кумулятивных потерь показана на рис. 4. В конце теста фактическая потеря sAdaHedge равна $A_T = 17{,}46011$. Каждая кривая построена по потерям соответствующего прогноза на одних и тех же 198 тестовых днях, поэтому потери методов сопоставимы на всём горизонте.

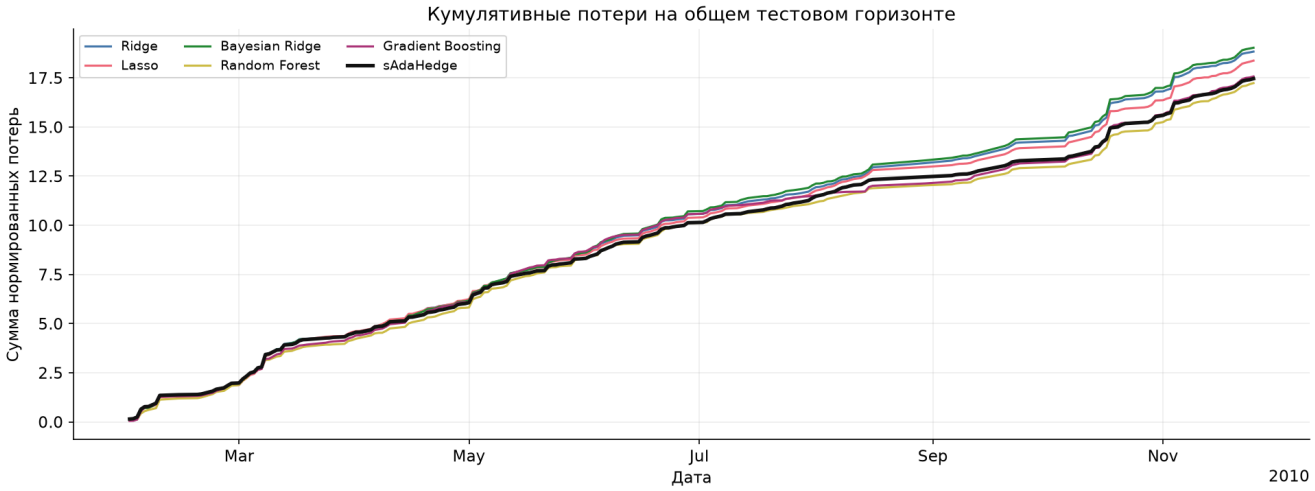


Рис. 4: Кумулятивные потери прогнозов экспертов и sAdaHedge на всём тесте. Чёрная линия показывает фактические потери прогноза sAdaHedge A_t.

4.5 Регрет на активных шагах и теоретическая граница

Регрет прогноза sAdaHedge на активных шагах эксперта равен

$$\widetilde{R}^i_{T,\mathrm{pred}} := \sum_{\substack{1 \leqslant t \leqslant T \\ i \in E_t}} \bigl(\ell(\gamma_t, y_t) - \ell(\gamma^i_t, y_t)\bigr).$$

Отрицательное значение означает, что на этих днях агрегатор понёс меньшие потери, чем эксперт. Результаты приведены в табл. 2.

Таблица 2: Сравнение на днях активности каждого эксперта. $\mathcal{L}^i_T$ — фактические потери эксперта на этих днях.

Эксперт	Дней	$\mathcal{L}^i_T$	$\widetilde{R}^i_{T,\mathrm{pred}}$
Ridge	136	11,07508	−0,01726
Lasso	198	18,37446	−0,91434
Bayesian Ridge	69	6,37518	0,07206
Random Forest	62	6,22361	0,17868
Gradient Boosting	129	11,06780	−0,05492

Регрет прогноза отрицателен для Ridge, Lasso и Gradient Boosting и положителен для Bayesian Ridge и Random Forest. Наибольший итоговый регрет равен 0,17868 относительно Random Forest. Правая часть теоретической оценки при $N = 5$ равна

$$B_T := 2\sqrt{V_T \ln 5} + S_T\left(\frac{4}{3}\ln 5 + 2\right) \approx 1{,}31346.$$

Теоретическая граница заметно превышает наблюдаемые значения.

Для каждого префикса $t = 1, \ldots, T$ и каждого эксперта проверено неравенство

$$\widetilde{R}^{i}_{t,\mathrm{pred}} \leqslant B_t$$

с численным допуском 10^{-9}; нарушений не обнаружено.

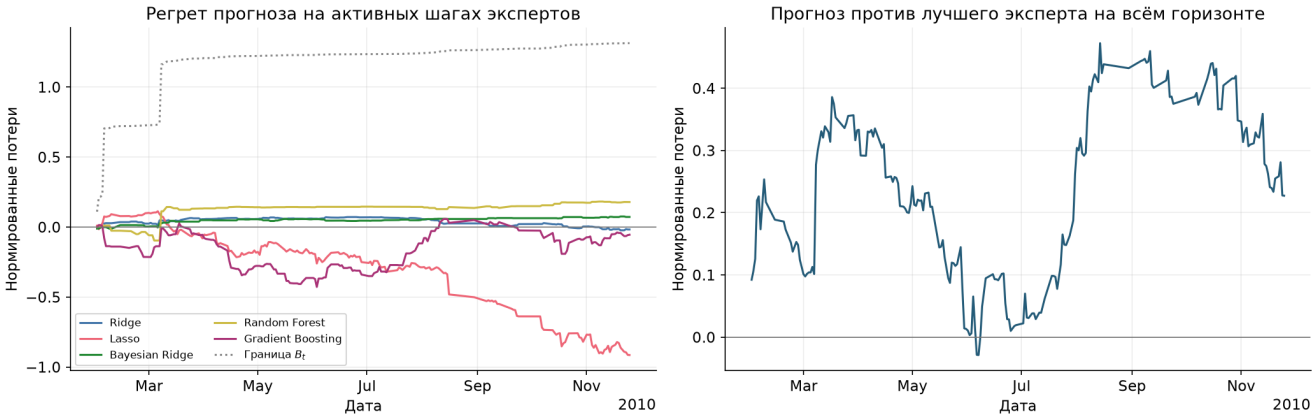


Рис. 5: Слева: регрет фактического прогноза относительно специалистов и теоретическая граница B_t. Справа: регрет прогноза относительно лучшего фиксированного эксперта на каждом полном префиксе теста.

Левая панель рис. 5 показывает регрет на активных шагах. На правой панели приведён другой критерий:

$$R_{t,\mathrm{full}} := A_t - \min_{i \in I} \sum_{s=1}^{t} \ell(\gamma^i_s, y_s),$$

где для каждого эксперта учитываются все тестовые дни, включая дни его сна. Минимум берётся отдельно на каждом префиксе; эксперт, достигающий минимума, может меняться с t. При $t = T$ получаем $R_{T,\mathrm{full}} = 0{,}22728$. Оценка (3.11) непосредственно относится к сравнению на активных шагах и не даёт такой же гарантии для $R_{t,\mathrm{full}}$.

Попарные кумулятивные сравнения представлены на рис. 6. В пределах каждой панели обе суммы вычислены по одним и тем же дням активности соответствующего эксперта. Между панелями наборы дней и их количество различаются, поэтому сами величины кумулятивных потерь на разных панелях не служат основанием для ранжирования экспертов.

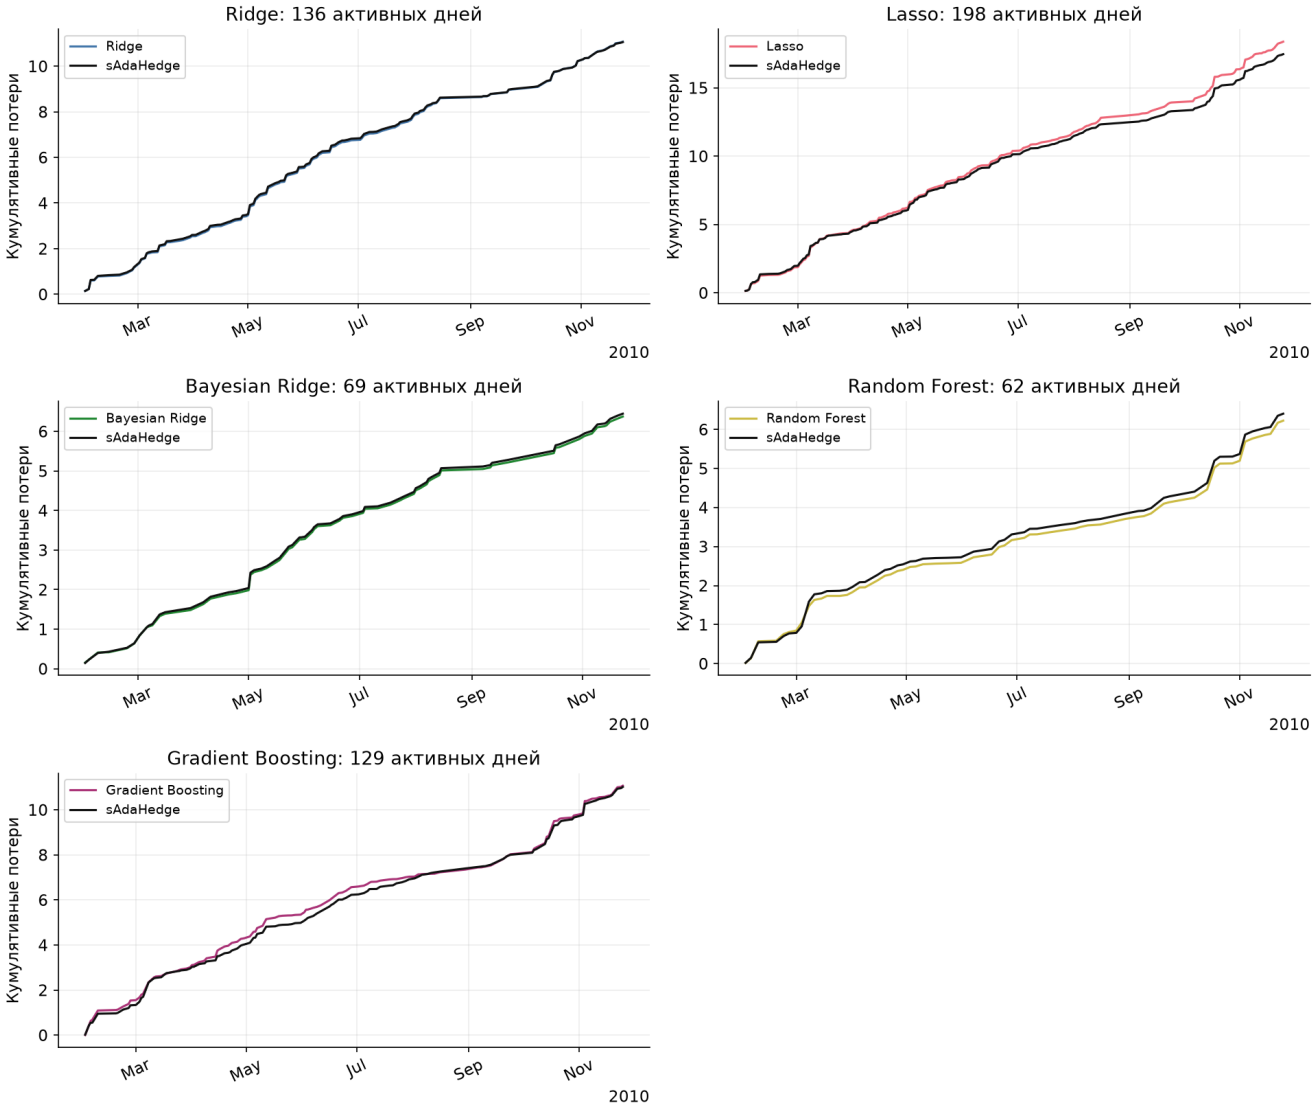


Рис. 6: Попарные сравнения на активных шагах: фактические потери прогнозов эксперта и sAdaHedge. На каждой панели используется собственное множество дней.

4.6 Динамика весов и выводы

На рис. 7 показаны веса активных экспертов и параметр обучения. Для изображения вес спящего эксперта принимается равным нулю. Поэтому часть резких изменений верхних кривых связана с календарным переключением множества E_t и последующей нормировкой весов.

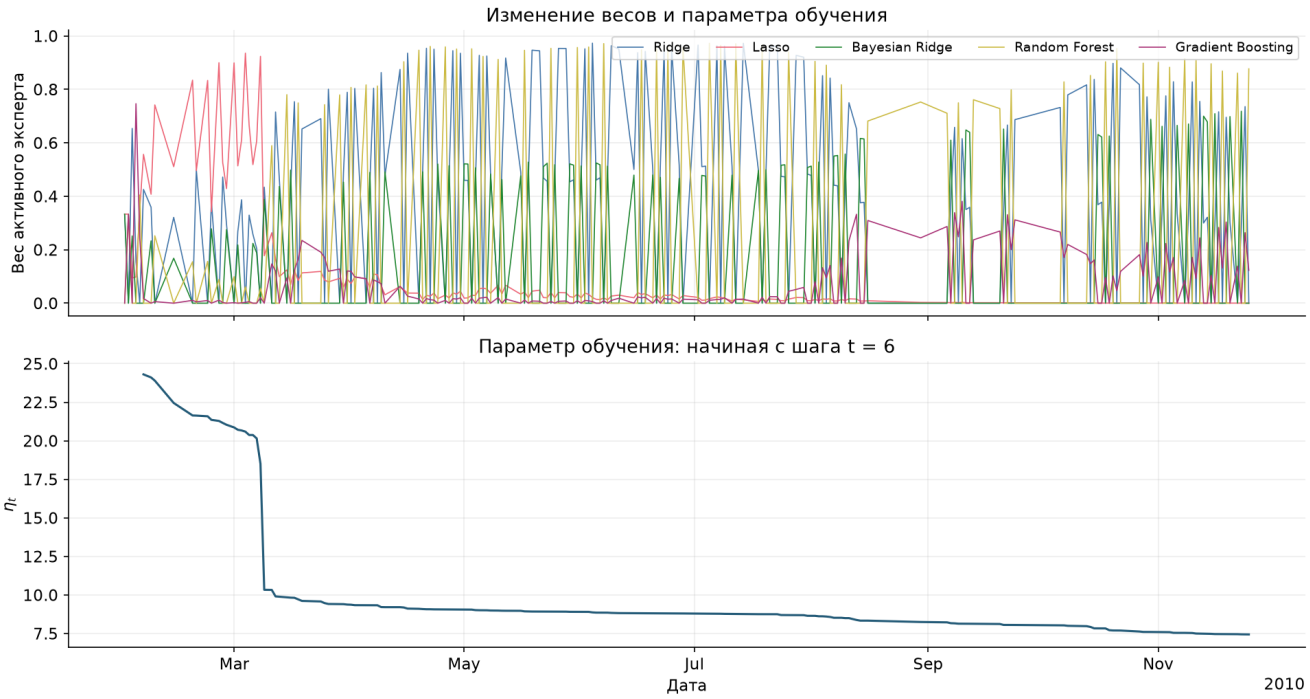


Рис. 7: Веса экспертов в прогнозе sAdaHedge (сверху) и параметр обучения η_t (снизу). Нижняя панель начинается с шестого шага; первые пять значений исключены только из изображения.

В начале теста заметную долю веса получает Lasso; далее в соответствующие дни активности существенный вес часто приходится на Ridge и Random Forest. Параметр η_t не возрастает, поскольку Δ_t не убывает.

В проведённом эксперименте sAdaHedge даёт близкое к лучшему фиксированному эксперту качество по несимметричной потере и небольшое преимущество над равномерным усреднением активных прогнозов. На активных шагах трёх из пяти экспертов регрет отрицателен; для двух остальных он положителен и остаётся в пределах теоретической оценки. При этом на всём тестовом горизонте лучшим по выбранной потере оказался Random Forest, активный в агрегаторе лишь два дня недели. Следовательно, качество фиксированного правила специализации существенно для интерпретации общего результата.

Выводы относятся к одному временному ряду, одному хронологическому разбиению и выбранным коэффициентам потерь. Небольшое преимущество перед равномерным усреднением здесь является наблюдаемым результатом; статистическая значимость этого различия не оценивалась. Дальнейшее сравнение может включать несколько последовательных тестовых периодов, другие числа активных экспертов и чувствительность к отношению λ_2/λ_1.

5 Заключение

В работе рассмотрена задача последовательного прогнозирования с советами экспертов и её обобщение на экспертов-специалистов, участвующих в прогнозе лишь на части шагов.

Изложены экспоненциальное смешивание потерь, адаптивный выбор параметра обучения и алгоритм sAdaHedge. Приведено доказательство оценки его регрета относительно каждого специалиста через накопленную дисперсию и максимальный размах потерь активных экспертов. Показано, что при выпуклой функции потерь эта оценка переносится со смеси потерь на фактические потери усреднённого прогноза.

Численный эксперимент на суточном электропотреблении продемонстрировал применение схемы с пятью регрессионными экспертами и специализацией по дням недели. Адаптивное взвешивание дало небольшое улучшение по сравнению с равномерным смешиванием, но не обеспечило превосходства над лучшим отдельным методом на всём горизонте.

Полученные результаты выделяют два компонента качества: сами прогнозы экспертов и правило их допуска к агрегированию. Адаптация весов позволяет использовать различия в качестве доступных прогнозов, однако не исправляет автоматически неудачный выбор множества активных экспертов. Кроме того, адаптивный параметр обучения не означает забывания прошлых потерь: в рассмотренной схеме они накапливаются за всё время работы. Эти особенности определяют дальнейшие направления исследования.

Открытые вопросы и направления продолжения

Следующие вопросы остаются открытыми в рамках проведённого исследования. Предлагаемые изменения требуют отдельных вычислительных экспериментов, а при изменении алгоритма — проверки условий и доказательства соответствующих гарантий.

1. **Как выбирать и обновлять специализацию?** В эксперименте активность один раз определяется по калибровочной выборке и зависит только от дня недели. Можно пересматривать её по скользящему окну прошлых ошибок, учитывать сезон, праздники и доступный на момент прогноза прогноз погоды. Следует сравнить разные числа активных экспертов, включая вариант $E_t = I$, и проверить, даёт ли специализация выигрыш по сравнению с агрегированием всех пяти моделей. При сохранении протокола sAdaHedge множество E_t должно оставаться непустым и определяться до раскрытия y_t. Сама оценка относительно выбранных специалистов не гарантирует высокого качества правила, которое выбирает их активность; оценивание и обучение этого правила составляют отдельную задачу.

2. **Как ускорить адаптацию к смене режима ряда?** Если лучший эксперт меняется со временем, старые потери могут долго влиять на его вес. Возможные модификации — скользящее окно потерь, их дисконтирование, перезапуски агрегатора и небольшое перераспределение веса между экспертами. Для оценки таких изменений целесообразно перейти от всего горизонта к сравнению на отрезках, связанному с постановкой адаптивного регрета [4]. В случае специалистов естественен критерий

$$\widetilde{R}^i_{[a,b],\mathrm{pred}} := \sum_{\substack{a \leqslant t \leqslant b \\ i \in E_t}} \bigl(\ell(\gamma_t, y_t) - \ell(\gamma^i_t, y_t)\bigr).$$

   Вопрос состоит в том, какие гарантии можно получить для него одновременно на разных временных отрезках и какова цена быстрой адаптации. Оценка на полном горизонте сама по себе этого не устанавливает; замена накопленных потерь оконными или дисконтированными требует нового анализа.

3. **Можно ли заменить бинарную активность степенью участия?** Вместо решения «активен или спит» можно задавать до наблюдения исхода коэффициент $c^i_t \in [0, 1]$, отражающий пригодность эксперта для текущего контекста. Это позволяет исследовать

плавный переход между режимами и уменьшить зависимость от жёсткого выбора трёх лучших моделей. Необходимо согласовать правило взвешивания с критерием качества, например с регретом

$$\sum_{t=1}^{T} c_t^i\big(\ell(\gamma_t, y_t) - \ell(\gamma_t^i, y_t)\big),$$

и определить соответствующие виртуальные потери. Простая замена индикатора активности на c_t^i в итоговой оценке без изменения доказательства недостаточна.

Список литературы

[1] Cesa-Bianchi N., Lugosi G. *Prediction, Learning, and Games*. Cambridge University Press, 2006. Страница книги.

[2] Freund Y., Schapire R. E. A decision-theoretic generalization of on-line learning and an application to boosting. *Journal of Computer and System Sciences*. 1997. Vol. 55, no. 1. P. 119–139. Авторская версия.

[3] V'yugin V. V., Shamsutdinov A. I. Trading-Network Order Formation with the Help of the Aggregation of Specialized Forecast Algorithms. *Journal of Communications Technology and Electronics*. 2016. Vol. 61. P. 1400–1410. https://doi.org/10.1134/S1064226916120251.

[4] Adamskiy D., Koolen W. M., Chernov A., Vovk V. A Closer Look at Adaptive Regret. *Journal of Machine Learning Research*. 2016. Vol. 17, no. 23. P. 1–21. https://www.jmlr.org/papers/v17/13-533.html.

[5] De Rooij S., Van Erven T., Grünwald P. D., Koolen W. M. Follow the Leader If You Can, Hedge If You Must. *Journal of Machine Learning Research*. 2014. Vol. 15, no. 37. P. 1281–1316. https://www.jmlr.org/papers/v15/rooij14a.html.

[6] Devaine M., Gaillard P., Goude Y., Stoltz G. Forecasting electricity consumption by aggregating specialized experts. *Machine Learning*. 2013. Vol. 90, no. 2. P. 231–260. https://doi.org/10.1007/s10994-012-5314-7.

[7] Hebrail G., Berard A. *Individual Household Electric Power Consumption* [набор данных]. UCI Machine Learning Repository, 2006. https://doi.org/10.24432/C58K54.