# Адаптивное агрегирование прогнозов специализированных экспертов

Е. А. Цыбулин

МГУ имени М. В. Ломоносова

31 октября 2026 г.

# План доклада

1. Онлайн-прогнозирование и сравнение с экспертами.
2. Экспоненциальные веса и адаптивный параметр обучения.
3. Спящие эксперты и алгоритм sAdaHedge.
4. Оценка регрета через дисперсию потерь.
5. Эксперимент с суточным электропотреблением.

# Временной ряд, эксперты и агрегатор

## Определение 1. Временной ряд

Временной ряд — последовательность исходов $y = (y_1, y_2, \ldots)$, где $y_t \in \mathcal{Y}$ и $t$ обозначает время.

## Определение 2. Экспертная стратегия

Эксперт $i$ — правило, выдающее по доступной истории прогноз $\gamma_t^i \in \mathcal{D}$ до наблюдения $y_t$. Здесь $\mathcal{D}$ — множество допустимых прогнозов.

## Определение 3. Агрегатор

Агрегатор — алгоритм, который по прогнозам экспертов и прошлым наблюдениям строит собственный прогноз $\gamma_t \in \mathcal{D}$.

Экспертами могут быть регрессионные модели, сезонные правила и оценки специалистов.

# Протокол онлайн-прогнозирования

Эксперты: $I = \{1, \ldots, N\}$. Исходы: $y_t \in \mathcal{Y}$. Прогнозы: $\gamma_t^i, \gamma_t \in \mathcal{D}$.

1. По истории до шага $t$ эксперты выдают $\gamma_t^1, \ldots, \gamma_t^N$.
2. Агрегатор выбирает собственный прогноз $\gamma_t$.
3. Среда раскрывает исход $y_t$.
4. Вычисляются потери. Агрегатор обновляет своё состояние.

**Прогноз и веса выбираются до раскрытия текущего исхода.**

Вероятностную модель ряда не предполагаем. Гарантия должна работать для любой последовательности исходов.

# Функции потерь

## Определение 4. Функция потерь

Функция $\ell : \mathcal{D} \times \mathcal{Y} \to [0, +\infty)$ сопоставляет прогнозу $\gamma$ и исходу $y$ величину ошибки $\ell(\gamma, y)$.

$$\text{Квадратичная:} \quad \ell(\gamma, y) = (\gamma - y)^2,$$

$$\text{Абсолютная:} \quad \ell(\gamma, y) = |\gamma - y|,$$

$$\text{Несимметричная:} \quad \ell(\gamma, y) = \lambda_1(\gamma - y)_+ + \lambda_2(y - \gamma)_+.$$

Здесь $(x)_+ = \max\{x, 0\}$, $\lambda_1, \lambda_2 > 0$. При $\lambda_2 > \lambda_1$ недооценка штрафуется сильнее переоценки.

Все три примера выпуклы по прогнозу $\gamma$. Это свойство понадобится при усреднении прогнозов.

# Кумулятивные потери и регрет

## Определение 5. Кумулятивные потери

Суммарные потери на первых $T$ шагах:

$$L_T := \sum_{t=1}^{T} \ell(\gamma_t, y_t), \qquad L_T^i := \sum_{t=1}^{T} \ell(\gamma_t^i, y_t).$$

## Определение 6. Регрет

Регрет относительно лучшего фиксированного эксперта:

$$R_T := L_T - \min_{i \in I} L_T^i.$$

- Лучший эксперт выбирается после всех $T$ шагов; его индекс фиксирован.
- Цель: малый добавочный проигрыш, в частности $R_T/T \to 0$.

Малый регрет сам по себе не означает малой абсолютной ошибки: важен уровень качества экспертов.

# Задача смешивания потерь

## Определение 7. Распределение на множестве экспертов

Вектор весов $p_t = (p_t^1, \ldots, p_t^N)$, для которого $p_t^i \geq 0$ и $\sum_{i=1}^N p_t^i = 1$.

## Определение 8. Смесь потерь

Средняя потеря экспертов с весами $p_t$ и её накопленное значение:

$$\ell_t := \sum_{i=1}^N p_t^i \ell_t^i, \qquad L_T := \sum_{t=1}^T \ell_t.$$

Веса выбираются до раскрытия текущих потерь $\ell_t^i$.

Здесь достаточно последовательности чисел $\ell_t^i$: конкретная функция потерь может не задаваться.

В классической постановке можно считать $\ell_t^i \in [0, 1]$. Позже оценка будет зависеть от фактического размаха потерь.

# Hedge: экспоненциальные веса

Фиксируем $\eta > 0$ и начальные веса $w_1^i = 1/N$.

1. Нормируем веса: $p_t^i = \dfrac{w_t^i}{\sum_j w_t^j}$.
2. Получаем потери и считаем $\ell_t = \sum_i p_t^i \ell_t^i$.
3. Обновляем веса: $w_{t+1}^i = w_t^i e^{-\eta \ell_t^i}$.

После раскрытия формулы обновления:

$$w_t^i = \frac{1}{N} e^{-\eta L_{t-1}^i}, \qquad p_t^i = \frac{e^{-\eta L_{t-1}^i}}{\sum_j e^{-\eta L_{t-1}^j}}.$$

**Меньшие накопленные потери дают больший вес.**

# Смешанная потеря и смешанная разность

## Определение 9. Смешанная потеря

При параметре $\eta > 0$ смешанная потеря и её сумма равны

$$m_t := -\frac{1}{\eta} \ln\left(\sum_i p_t^i e^{-\eta \ell_t^i}\right), \qquad M_T := \sum_{t=1}^{T} m_t.$$

## Определение 10. Смешанная разность

$$\delta_t := \ell_t - m_t, \qquad \Delta_T := \sum_{t=1}^{T} \delta_t.$$

**Свойства:**

$$\min_i \ell_t^i \le m_t \le \ell_t \le \max_i \ell_t^i, \qquad L_T = M_T + \Delta_T.$$

Неравенство Йенсена даёт $m_t \le \ell_t$, поэтому $\delta_t \ge 0$.

# Потенциал и сравнение с экспертом

Положим $W_t = \sum_i w_t^i$. При постоянном $\eta$:

$$\sum_i p_t^i e^{-\eta \ell_t^i} = \frac{W_{t+1}}{W_t}, \qquad M_T = -\frac{1}{\eta} \sum_{t=1}^{T} \ln \frac{W_{t+1}}{W_t} = -\frac{1}{\eta} \ln W_{T+1}.$$

Так как $W_1 = 1$ и $W_{T+1} \geq \frac{1}{N} e^{-\eta L_T^i}$,

$$M_T \leq L_T^i + \frac{\ln N}{\eta} \qquad \text{для любого } i.$$

## Разложение регрета

$$L_T - L_T^i = (M_T - L_T^i) + \Delta_T \leq \frac{\ln N}{\eta} + \Delta_T.$$

# Переменный параметр обучения

При каждом новом $\eta_t$ пересчитываем веса по всей истории:

$$w_t^i = \frac{1}{N} e^{-\eta_t L_{t-1}^i}, \qquad p_t^i = \frac{w_t^i}{\sum_j w_t^j}.$$

Обозначим через $M_t^\eta$ потенциал с постоянным параметром $\eta$. Тогда

$$m_t = M_t^{\eta_t} - M_{t-1}^{\eta_t}.$$

**Если $\eta_1 \geq \eta_2 \geq \cdots \geq \eta_T > 0$**

$$M_T = \sum_{t=1}^{T} m_t \leq M_T^{\eta_T} \leq L_T^i + \frac{\ln N}{\eta_T}.$$

# Эксперты-специалисты

**Определение 11. Эксперт-специалист**

Специалист — эксперт, участвующий в прогнозировании лишь на части шагов. На шаге $t$ множество $E_t \subseteq I$ содержит активных экспертов; эксперты из $I \setminus E_t$ называются спящими.

- Специализация может зависеть от дня недели, сезона или режима ряда.
- Эксперт может отсутствовать из-за недоступных признаков.
- Его качество следует оценивать на шагах, когда он участвовал.

**Условия протокола.** $N \geq 2$, $E_t \neq \varnothing$. Множество $E_t$ определяется до раскрытия текущего исхода или текущих потерь.

# Нормировка на активных экспертах

Глобальные веса хранят информацию обо всех экспертах:

$$w_t^i = \frac{1}{N} e^{-\eta_t L_{t-1}^i}, \qquad p_t^i = \frac{w_t^i}{\sum_j w_t^j}.$$

## Определение 12. Нормированные веса активных экспертов

Распределение весов на непустом множестве $E_t$:

$$p_t^{i,E_t} := \frac{p_t^i}{\sum_{j \in E_t} p_t^j}, \qquad i \in E_t.$$

Потеря смеси теперь учитывает только активных экспертов:

$$\ell_t = \sum_{i \in E_t} p_t^{i,E_t} \ell_t^i.$$

При конечном $\eta_t$ веса положительны. Случай $\eta_t = \infty$ рассмотрим отдельно.

# Виртуальные потери спящих экспертов

## Определение 13. Виртуальные потери в sAdaHedge

На шагах сна эксперту приписывается смешанная потеря агрегатора: $\ell_t^i := m_t$ при $i \notin E_t$.

## Определение 14. Расширенные кумулятивные потери

К фактическим потерям на активных шагах добавляются виртуальные потери:

$$\mathcal{L}_T^i := \sum_{\substack{1 \le t \le T \\ i \in E_t}} \ell_t^i, \qquad L_T^i := \mathcal{L}_T^i + \sum_{\substack{1 \le t \le T \\ i \notin E_t}} m_t.$$

Каждый эксперт получает последовательность потерь на всех шагах. К ней можно применить оценки экспоненциальных весов.

Виртуальная потеря равна $m_t$; скрытая фактическая потеря спящего эксперта в обновлении не используется.

# Как вычислить смешанную потерю

Пусть $q_t = \sum_{i \in E_t} p_t^i > 0$. Подставим виртуальные потери:

$$e^{-\eta_t m_t} = \sum_{i \in E_t} p_t^i e^{-\eta_t \ell_t^i} + (1 - q_t) e^{-\eta_t m_t}.$$

Перенос последнего слагаемого даёт

$$q_t e^{-\eta_t m_t} = \sum_{i \in E_t} p_t^i e^{-\eta_t \ell_t^i}.$$

## Формула через доступные потери

$$m_t = -\frac{1}{\eta_t} \ln \left( \sum_{i \in E_t} p_t^{i, E_t} e^{-\eta_t \ell_t^i} \right).$$

Правая часть зависит только от доступных потерь и известных весов: цикличности нет.

# Адаптивный параметр sAdaHedge

Как и раньше, определим

$$\delta_t = \ell_t - m_t \geq 0, \qquad \Delta_t = \Delta_{t-1} + \delta_t, \qquad \Delta_0 = 0.$$

Параметр обучения выбирается до текущих потерь:

$$\eta_t = \begin{cases} \dfrac{\ln N}{\Delta_{t-1}}, & \Delta_{t-1} > 0, \\ \infty, & \Delta_{t-1} = 0. \end{cases}$$

- $\Delta_t$ не убывает, поэтому $\eta_t$ не возрастает.
- Горизонт $T$ и будущий размах потерь заранее не нужны.
- При большем накопленном разрыве веса менее сосредоточены.

# Начальный случай: смешанная разность равна нулю

Инициализация: $L_0^i = 0$, $w_1^i = 1/N$, $\Delta_0 = 0$. Пока $\Delta_{t-1} = 0$, расширенные потери всех экспертов совпадают. Используем предельное соглашение:

$$\eta_t = \infty, \qquad \frac{1}{\eta_t} = 0, \qquad p_t^i = \frac{1}{N}, \qquad p_t^{i,E_t} = \frac{1}{|E_t|}.$$

$$m_t = \min_{i \in E_t} \ell_t^i, \qquad \delta_t = \frac{1}{|E_t|} \sum_{i \in E_t} \ell_t^i - \min_{i \in E_t} \ell_t^i.$$

**При первом различии активных потерь получаем $\delta_t > 0$.** На следующем шаге $\eta_{t+1}$ уже конечен.

Если все активные потери равны, виртуальные потери совпадают с ними; равенство расширенных потерь сохраняется.

# Один шаг sAdaHedge

**До раскрытия потерь**

1. Получить $E_t$. Вычислить $\eta_t$ по $\Delta_{t-1}$.
2. По $L^i_{t-1}$ пересчитать веса и нормировать их на $E_t$.
3. При прогнозировании выдать $\gamma_t = \sum_{i \in E_t} p_t^{i,E_t} \gamma_t^i$.

**После раскрытия потерь**

4. Вычислить $\ell_t$, $m_t$, $\delta_t = \ell_t - m_t$.
5. Спящим экспертам присвоить $\ell_t^i = m_t$.
6. Обновить $L_t^i = L_{t-1}^i + \ell_t^i$ и $\Delta_t = \Delta_{t-1} + \delta_t$.

На следующем шаге веса вычисляются заново с новым $\eta_{t+1}$. При переменном параметре простой множитель $e^{-\eta_t \ell_t^i}$ не заменяет этот пересчёт.

# Регрет относительно специалиста

## Определение 15. Регрет специалиста

Разность потерь смеси и эксперта на шагах активности этого эксперта:

$$\widetilde{R}_T^i := \sum_{\substack{1 \le t \le T \\ i \in E_t}} (\ell_t - \ell_t^i).$$

## Определение 16. Расширенный регрет

Регрет по расширенным потерям на всём горизонте: $R_T^i := L_T - L_T^i$.

Во время сна $\ell_t^i = m_t$, поэтому

$$R_T^i = \widetilde{R}_T^i + \sum_{\substack{1 \le t \le T \\ i \notin E_t}} \delta_t \ge \widetilde{R}_T^i.$$

Для разных специалистов наборы активных дней различаются; $\delta_t \ge 0$ даёт сравнение регретов.

# Дисперсия и размах потерь

## Определение 17. Размах потерь

Разность максимальной и минимальной потерь активных экспертов:

$$s_t := \max_{i \in E_t} \ell_t^i - \min_{i \in E_t} \ell_t^i, \qquad S_T := \max_{1 \le t \le T} s_t.$$

## Определение 18. Взвешенная дисперсия потерь

Дисперсия относительно распределения активных весов и её сумма:

$$v_t := \sum_{i \in E_t} p_t^{i, E_t} (\ell_t^i - \ell_t)^2, \qquad V_T := \sum_{t=1}^{T} v_t.$$

- Из границ смешанной потери следует $0 \le \delta_t \le s_t$.
- При совпадении всех активных потерь $s_t = v_t = \delta_t = 0$.

Дисперсия определяется по весам экспертов; вероятностная модель ряда не требуется.

# Оценка регрета sAdaHedge

**Теорема Вьюгина–Шамсутдинова**

При $N \geq 2$, непустых $E_t$ и описанном протоколе для любого эксперта $i$ и любого $T \geq 1$ выполнено

$$\widetilde{R}_T^i \leq 2\sqrt{V_T \ln N} + S_T \left( \frac{4}{3} \ln N + 2 \right).$$

- Одна граница одновременно для всех специалистов.
- Сложность последовательности входит через $V_T$ и $S_T$.
- При $s_t \leq 1$ имеем $V_T \leq T/4$ и порядок $O(\sqrt{T \ln N} + \ln N)$.

# Шаг 1. Сведение регрета к смешанной разности

Применим оценку с невозрастающим $\eta_t$ к расширенным потерям:

$$M_T - L_T^i \le \frac{\ln N}{\eta_T} = \Delta_{T-1} \le \Delta_T.$$

Используя $L_T = M_T + \Delta_T$, получаем

$$R_T^i = L_T - L_T^i = (M_T - L_T^i) + \Delta_T \le 2\Delta_T.$$

**Промежуточная гарантия**

$$\widetilde{R}_T^i \le R_T^i \le 2\Delta_T.$$

Осталось оценить $\Delta_T$ через наблюдаемую дисперсию и размах.

При $\Delta_{T-1} = 0$ используется соглашение $1/\eta_T = 0$ и тот же предельный смысл потенциала.

# Шаг 2. Одношаговая оценка через дисперсию

Для $s_t > 0$ и конечного $\eta_t$ неравенство Бернштейна даёт

$$\delta_t \le \frac{e^{s_t\eta_t} - 1 - s_t\eta_t}{\eta_t s_t^2}\, v_t.$$

Для суммирования удобнее следующее следствие:

**Вспомогательное неравенство**

$$\frac{\delta_t}{\eta_t} \le \frac{1}{2}v_t + \frac{1}{3}s_t\delta_t.$$

- Оно верно при любом конечном $\eta_t > 0$.
- При $s_t = 0$ обе части равны нулю.
- При $\eta_t = \infty$ левая часть равна нулю.

# Шаг 3. Накопление смешанных разностей

Телескопируем квадраты и используем $\Delta_{t-1} = \ln N/\eta_t$:

$$\begin{aligned}\Delta_T^2 &= \sum_{t=1}^{T} \left(2\delta_t \Delta_{t-1} + \delta_t^2\right) \\ &\le 2\ln N \sum_{t=1}^{T} \frac{\delta_t}{\eta_t} + S_T \Delta_T \\ &\le 2\ln N \sum_{t=1}^{T} \left(\frac{1}{2} v_t + \frac{1}{3} s_t \delta_t\right) + S_T \Delta_T.\end{aligned}$$

Здесь $\delta_t^2 \le s_t \delta_t$ и $s_t \le S_T$.

$$\Delta_T^2 \le V_T \ln N + \left(\frac{2}{3}\ln N + 1\right) S_T \Delta_T.$$

# Шаг 4. Решение квадратного неравенства

Обозначим

$$a = V_T \ln N, \qquad b = S_T \left( \frac{2}{3} \ln N + 1 \right).$$

Из $\Delta_T^2 \le a + b\Delta_T$ и $a, b \ge 0$ следует

$$\Delta_T \le \frac{b + \sqrt{b^2 + 4a}}{2} \le \sqrt{a} + b.$$

Подставляя в промежуточную гарантию, получаем

$$\widetilde{R}_T^i \le R_T^i \le 2\Delta_T \le 2\sqrt{V_T \ln N} + S_T \left( \frac{4}{3} \ln N + 2 \right).$$

**Граница следует из контроля накопленного разрыва между $\ell_t$ и $m_t$.**

# Переход от смеси потерь к прогнозам

Пусть $\mathcal{D}$ выпукло, а $\ell(\gamma, y)$ выпукла по $\gamma$. Агрегатор выдаёт

$$\gamma_t = \sum_{i \in E_t} p_t^{i, E_t} \gamma_t^i.$$

По Йенсену фактическая потеря не больше смеси потерь:

$$\ell(\gamma_t, y_t) \leq \sum_{i \in E_t} p_t^{i, E_t} \ell(\gamma_t^i, y_t) = \ell_t.$$

**Определение 19. Регрет прогноза на активных шагах**

$$\widetilde{R}^i_{T,\text{pred}} := \sum_{\substack{1 \leq t \leq T \\ i \in E_t}} \big(\ell(\gamma_t, y_t) - \ell(\gamma_t^i, y_t)\big).$$

**Следствие:** $\widetilde{R}^i_{T,\text{pred}} \leq \widetilde{R}^i_T$; оценка теоремы сохраняется для прогнозов.

Суммарные фактические потери прогноза: $A_T = \sum_t \ell(\gamma_t, y_t)$.

# Данные: суточное электропотребление

Одно домохозяйство во Франции, декабрь 2006 – ноябрь 2010.




Суточная энергия: $Y_d = \frac{1}{60} \sum_{r=1}^{1440} P_{d,r}$, кВт·ч. Полные сутки: 1358 из 1442. Пропуски сохранены.

# Хронологический протокол эксперимента

После построения признаков доступны 989 наблюдений.

| Часть | Дней | Начало | Конец |
|---|---|---|---|
| Обучение экспертов | 593 | 17.01.2007 | 17.04.2009 |
| Выбор активности | 198 | 18.04.2009 | 29.01.2010 |
| Тестирование | 198 | 31.01.2010 | 25.11.2010 |

- 20 признаков: лаги, прошлые скользящие статистики, календарь.
- Прогноз на один день вперёд; прошлые тестовые исходы доступны.
- Эксперты после обучения фиксированы. На тесте меняются веса.

Шаг $t$ означает доступный тестовый день. Подробные признаки: резерв А6.

# Пять экспертов и специализация по дням недели

Для каждого дня недели по калибровке выбраны три эксперта с наименьшей средней несимметричной потерей.

| Эксперт | Пн | Вт | Ср | Чт | Пт | Сб | Вс |
|---|---|---|---|---|---|---|---|
| Ridge | | • | • | | • | • | • |
| Lasso | • | • | • | • | • | • | • |
| Bayesian Ridge | | • | | | | • | • |
| Random Forest | • | | | • | | | |
| Gradient Boosting | • | | • | • | • | | |

Во всех тестовых днях $|E_t| = 3$. Правило активности известно до наблюдения потребления.

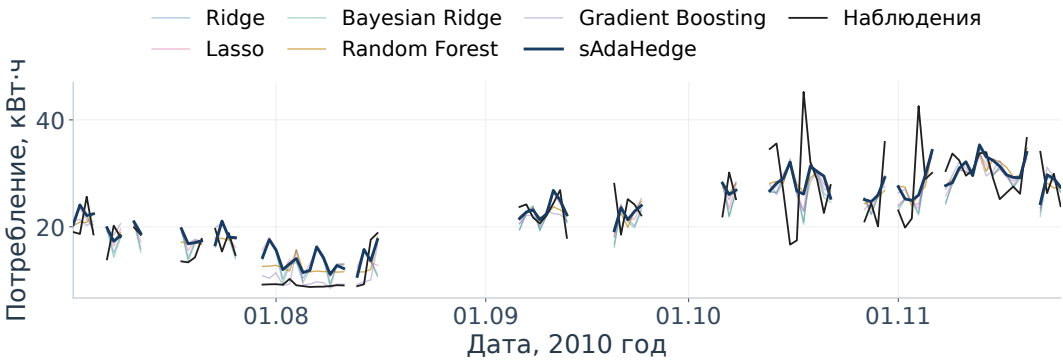
# Критерий сравнения и запуск агрегатора

Функция потерь:

$$\ell(\gamma, y) = (\gamma - y)_+ + 2(y - \gamma)_+.$$

- Недооценка вдвое дороже равной по величине переоценки.
- На старте теста $L_0^i = 0$, $\Delta_0 = 0$: калибровка не входит в историю весов.
- Сравнение на всех 198 днях: пять экспертов, sAdaHedge, среднее активных и среднее всех экспертов.

# Прогнозы на последних 90 доступных днях




Агрегатор воспроизводит общий уровень потребления, но сглаживает часть резких суточных скачков.

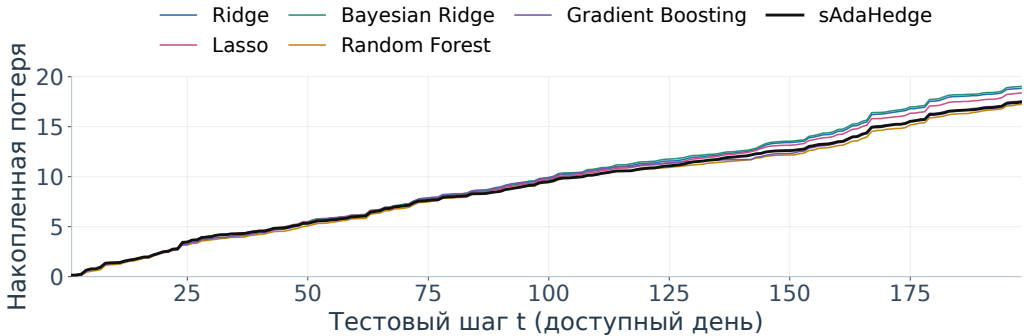
Разрывы линий соответствуют исключённым календарным дням. Наблюдения и прогнозы приведены в физических единицах.

# Качество на всём тестовом горизонте

| Метод | Суммарная потеря | MAE | RMSE |
|---|---|---|---|
| Random Forest | 17,23283 | 3,97616 | 5,25696 |
| **sAdaHedge** | 17,46011 | 4,08681 | 5,42988 |
| Среднее активных | 17,53792 | 4,05079 | 5,41996 |
| Gradient Boosting | 17,57012 | 3,85351 | 5,33035 |
| Среднее всех | 17,88205 | 4,01153 | 5,44192 |
| Lasso | 18,37446 | 4,18644 | 5,60173 |
| Ridge | 18,83564 | 4,19493 | 5,74170 |
| Bayesian Ridge | 19,02995 | 4,21581 | 5,80568 |

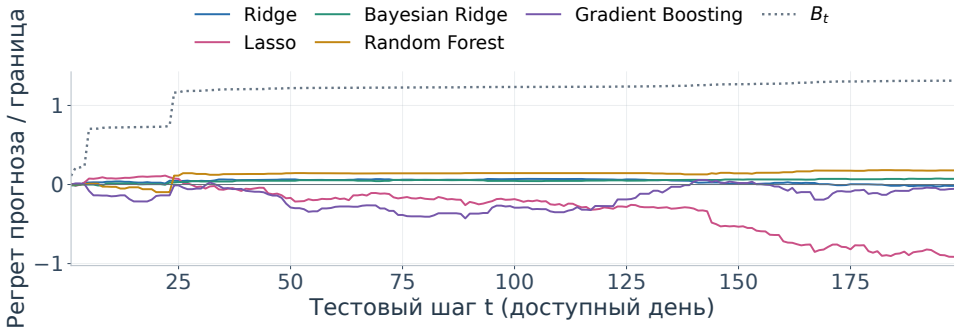
По несимметричной потере sAdaHedge: на 1,32% хуже Random Forest; на 0,44% лучше среднего активных.

# Кумулятивные потери прогнозов




$$A_T = \sum_{t=1}^{T} \ell(\gamma_t, y_t) = 17{,}46011.$$

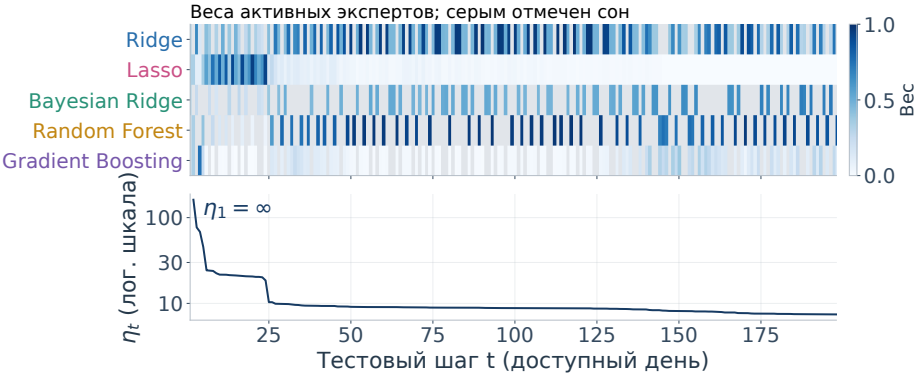
# Регрет прогноза и теоретическая граница




$$\max_i \widetilde{R}^i_{T,\mathrm{pred}} = 0{,}17868 \;<\; B_T = 1{,}31346.$$

На каждом префиксе теста и для каждого эксперта проверено $\widetilde{R}^i_{t,\mathrm{pred}} \le B_t$. Сравнение проводится на днях активности соответствующего эксперта.

# Динамика весов и параметра обучения



# Результаты и ограничения

- sAdaHedge адаптирует веса доступных экспертов и даёт гарантию относительно каждого специалиста на его активных шагах.
- При выпуклой потере гарантия переносится на усреднённый прогноз.
- В эксперименте получено небольшое улучшение относительно среднего активных; лучшим на всём горизонте оказался Random Forest.
- Адаптация весов не выбирает правило специализации и не забывает старые потери.

# Направления продолжения

1. **Выбор активности.** Сравнить фиксированную специализацию, всех активных экспертов и обновление специализации по прошлым ошибкам.
2. **Смена режима.** Исследовать окна, дисконтирование и перезапуски; оценивать регрет на временных отрезках [5].
3. **Устойчивость результатов.** Повторить сравнение на нескольких хронологических разбиениях и при разных отношениях штрафов.

**Ближайший шаг: отделить вклад выбора экспертов от вклада адаптации весов.**

# Резерв A1. Монотонность потенциала по параметру

Зафиксируем потери $L_T^i$ и начальные веса $w_1^i$, $\sum_i w_1^i = 1$. Пусть $0 < \eta \le \mu$ и $r = \eta/\mu \in (0, 1]$.

$$Z_\eta := \sum_i w_1^i e^{-\eta L_T^i} = \sum_i w_1^i \left(e^{-\mu L_T^i}\right)^r.$$

По вогнутости $x \mapsto x^r$:

$$Z_\eta \le \left(\sum_i w_1^i e^{-\mu L_T^i}\right)^r = Z_\mu^r.$$

Следовательно,

$$M_T^\eta = -\frac{1}{\eta} \ln Z_\eta \ge -\frac{r}{\eta} \ln Z_\mu = M_T^\mu.$$

**Кумулятивная смешанная потеря невозрастает по $\eta$.**

При сравнении параметров последовательность потерь фиксирована, включая уже полученные виртуальные потери.

# Резерв A2. Оценка при невозрастающем параметре

Из определения весов при текущем $\eta_t$ имеем

$$m_t = M_t^{\eta_t} - M_{t-1}^{\eta_t}, \qquad M_0^{\eta} = 0.$$

Суммируем и группируем члены:

$$\begin{aligned} M_T &= \sum_{t=1}^{T} \left( M_t^{\eta_t} - M_{t-1}^{\eta_t} \right) \\ &= M_T^{\eta_T} + \sum_{t=1}^{T-1} \left( M_t^{\eta_t} - M_t^{\eta_{t+1}} \right). \end{aligned}$$

При $\eta_t \geq \eta_{t+1}$ монотонность даёт $M_t^{\eta_t} \leq M_t^{\eta_{t+1}}$.

$$M_T \leq M_T^{\eta_T} \leq L_T^i + \frac{\ln N}{\eta_T}.$$

# Резерв A3. Начальные и вырожденные случаи

**Почему при $\Delta_{t-1} = 0$ расширенные потери равны?**

- Изначально все $L_0^i = 0$.
- При равных $L_{t-1}^i$ активные веса равномерны.
- Если $\delta_t = 0$, среднее активных потерь равно их минимуму. Значит, все эти потери равны $m_t$.
- Спящим экспертам тоже присваивается $m_t$: все $L_t^i$ остаются равными.

**Совпадение активных потерь.** При $s_t = 0$, в том числе при $|E_t| = 1$, получаем $m_t = \ell_t$, $\delta_t = v_t = 0$. **Пустое $E_t$.** Нормировка не определена. Протокол требует хотя бы одного доступного эксперта на каждом шаге.

# Резерв A4. Применение неравенства Бернштейна

Для $X \in [0,1]$ и $a > 0$ используем

$$\ln \mathbb{E} e^{-a(X-\mathbb{E}X)} \le \mathrm{Var}(X)(e^a - 1 - a).$$

При $s_t > 0$ положим $\ell_t^- = \min_{i \in E_t} \ell_t^i$ и зададим

$$X = \frac{\ell_t^i - \ell_t^-}{s_t} \quad \text{с вероятностью } p_t^{i,E_t}, \qquad a = s_t \eta_t.$$

Тогда $\mathbb{E}X = (\ell_t - \ell_t^-)/s_t$, $\mathrm{Var}(X) = v_t/s_t^2$ и

$$\begin{aligned} \eta_t \delta_t &= \ln \sum_{i \in E_t} p_t^{i,E_t} e^{-\eta_t(\ell_t^i - \ell_t)} \\ &= \ln \mathbb{E} e^{-s_t \eta_t (X - \mathbb{E}X)} \le \frac{v_t}{s_t^2} \left(e^{s_t \eta_t} - 1 - s_t \eta_t\right). \end{aligned}$$

Делим на $\eta_t > 0$ и получаем одношаговую оценку.

Неравенство Бернштейна в этой форме: Cesa-Bianchi–Lugosi, леммы A.4–A.5 [1].

# Резерв A5. Переход к оценке отношения смешанной разности

Обозначим $x = s_t\eta_t > 0$. Если $0 < x < 3$, то

$$e^x - 1 - x = \sum_{k=2}^{\infty} \frac{x^k}{k!} \le \frac{x^2}{2} \sum_{j=0}^{\infty} (x/3)^j = \frac{x^2}{2(1 - x/3)}.$$

Здесь $k! \ge 2 \cdot 3^{k-2}$ при $k \ge 2$. Поэтому

$$\delta_t \le \frac{\eta_t v_t}{2(1 - s_t\eta_t/3)} \quad \Longrightarrow \quad \frac{\delta_t}{\eta_t} \le \frac{1}{2} v_t + \frac{1}{3} s_t\delta_t.$$

Если $x \ge 3$, то непосредственно

$$\frac{\delta_t}{\eta_t} = \frac{s_t\delta_t}{x} \le \frac{1}{3} s_t\delta_t \le \frac{1}{2} v_t + \frac{1}{3} s_t\delta_t.$$

Таким образом, неравенство верно для всех конечных $\eta_t > 0$, а не только при малом произведении $s_t\eta_t$.

# Резерв А6. Признаки и обработка пропусков

| Группа признаков | Число |
|---|---|
| Лаги 1, 2, 7, 14, 28 календарных дней | 5 |
| Среднее, стандартное отклонение и число известных значений в окнах 7 и 28 дней | 6 |
| Индикаторы дня недели | 7 |
| Синус и косинус годового цикла | 2 |
| Всего | 20 |

- Скользящие окна используют только дни до прогнозируемого.
- Требуется не менее 5 значений в окне 7 дней и 20 в окне 28 дней.
- После построения признаков удаляются строки с неизвестной целью или необходимыми признаками. Пропуски не заполняются.

# Резерв A7. Настройки регрессионных экспертов

| Эксперт | Выбранные параметры |
|---|---|
| Ridge | Коэффициент регуляризации 100 |
| Lasso | Коэффициент регуляризации 0,5 |
| Bayesian Ridge | Одна конфигурация без перебора |
| Random Forest | 150 деревьев, глубина не ограничена, минимум 10 наблюдений в листе |
| Gradient Boosting | 150 деревьев глубины 2, скорость обучения 0,03 |

- Подбор по несимметричной потере: три временных разбиения внутри обучающей части, расширяющееся окно.
- Стандартизация линейных моделей обучается внутри каждого разбиения.
- Отрицательные прогнозы заменяются нулём. Начальное число генератора: 42.

# Резерв A8. Сравнения на активных днях

Для каждого эксперта используются только дни его активности.

| Эксперт | Дней | $\mathcal{L}_T^i$ | $\widetilde{R}^i_{T,\mathrm{pred}}$ |
|---|---|---|---|
| Ridge | 136 | 11,07508 | −0,01726 |
| Lasso | 198 | 18,37446 | −0,91434 |
| Bayesian Ridge | 69 | 6,37518 | 0,07206 |
| Random Forest | 62 | 6,22361 | 0,17868 |
| Gradient Boosting | 129 | 11,06780 | −0,05492 |

- У трёх из пяти экспертов регрет прогноза отрицателен.
- Максимальный итоговый регрет: 0,17868 относительно Random Forest.
- Теоретическая граница: $B_T \approx 1{,}31346$.

Проверки всех префиксов выполнены с допуском $10^{-9}$. Наборы активных дней у разных экспертов различаются.

# Резерв A9. Литература: основные теоретические источники



N. Cesa-Bianchi, G. Lugosi. *Prediction, Learning, and Games*. Cambridge University Press, 2006. Страница книги.


Y. Freund, R. E. Schapire. A decision-theoretic generalization of on-line learning and an application to boosting. *J. Computer and System Sciences*, 55(1):119–139, 1997. Авторская версия.


V. V. V'yugin, A. I. Shamsutdinov. Trading-Network Order Formation with the Help of the Aggregation of Specialized Forecast Algorithms. *J. Communications Technology and Electronics*, 61:1400–1410, 2016. DOI: 10.1134/S1064226916120251.


S. De Rooij, T. Van Erven, P. D. Grünwald, W. M. Koolen. Follow the Leader If You Can, Hedge If You Must. *JMLR*, 15(37):1281–1316, 2014. Текст статьи.

# Резерв A10. Литература: продолжение и данные




D. Adamskiy, W. M. Koolen, A. Chernov, V. Vovk. A Closer Look at Adaptive Regret. *Journal of Machine Learning Research*, 17(23):1–21, 2016. Текст статьи.



M. Devaine, P. Gaillard, Y. Goude, G. Stoltz. Forecasting electricity consumption by aggregating specialized experts. *Machine Learning*, 90(2):231–260, 2013. DOI: 10.1007/s10994-012-5314-7.



G. Hebrail, A. Berard. *Individual Household Electric Power Consumption*. UCI Machine Learning Repository, 2006. DOI: 10.24432/C58K54. Лицензия CC BY 4.0.